

Compilers

Bert De Saffel

Master in de Industriële Wetenschappen: Informatica Academiejaar 2018–2019

Gecompileerd op 26 april 2019

Inhoudsopgave

I	Theorie	5
1	Inleiding	6
1.1	Compilers	6
1.2	Basiswerking compilers	6
1.3	Abstract Syntax Tree	7
1.3.1	Contextvrije grammatica's	7
1.3.2	Opbouw AST	8
1.3.3	Interpreter	10
2	Lexicale Analyse	11
2.1	Lexicale tokens	11
2.2	Eindige automaten	11
2.3	Opbouw deterministische eindige automaat	13
2.3.1	Conversie NFA naar DFA	15
3	Parsing	17
3.1	Inleiding	17
3.2	Context-vrije grammatica	17
3.2.1	Afleiden van een zin	17
3.2.2	Ambigue grammatica	18
3.2.3	Grammatica disambiguëren	20
3.3	Predictive Parsing	20
3.3.1	First and follow sets	21
3.3.2	Opstellen Predictive Parsing Tabel	22
3.3.3	LL(1) Parsers	23

3.3.4	Error Recovery	23
3.4	LR(k) parser	24
3.5	Local Error Recovery	24
4	Abstracte syntax	25
4.1	Semantische acties	25
4.2	Abstract Parse Tree Construction	28
4.2.1	Posities	28
5	Semantische analyse	29
5.1	Symbooltabellen	29
5.1.1	Efficiëntere symbooltabellen	30
5.2	Type Checking	31
5.2.1	Expressies	31
5.2.2	Variabelen	31
5.2.3	Declaraties	32
6	Activation Records	33
6.1	Stack Frames	34
6.1.1	Static Link	34
6.1.2	Escapes	34
6.2	Frames in de Tiger compiler	36
6.2.1	Frame Interface	36
6.2.2	Creatie en initialisatie van frames	37
6.2.3	Escapes berekenen	37
6.2.4	Temporaries en Labels	37
7	Intermediate Representations	38
7.0.1	Omzetting enkelvoudige veranderlijken	39
8	Basisblokken en traces	40
8.1	Canonical trees	40
8.2	Linearizeren	40
8.3	Basic blocks	40
8.3.1	Traces aanmaken	40
9	Instructieselectie	41

<i>INHOUDSOPGAVE</i>	3
10 Liveness analyse	42
10.1 Control Flow Graphs	42
10.2 Statische approximatie	43
10.3 Interference Graph	43
11 Registerallocatie	44
11.1 Register Coalescing	44
12 Data Flow Analysis	45
12.1 Analyse en transformaties	45
12.2 Reaching definitions	46
12.3 Available expressions	46
12.4 Optimalisaties	47
12.5 Snellere analyses	47
12.6 Incrementele analyses	48
12.7 Value Numbering	48
12.8 Incremente livenessanalyse	48
12.9 Alias Analysis	48
13 Loop Optimizations	49
13.1 Dominators	49
13.1.1 Header loops	49
13.1.2 Loop preheader	50
13.2 Loop Invariant Computations	50
13.2.1 Conversie lussen voor LCIM	50
13.3 Inductieveranderlijken	50
13.4 Loop unrolling	50
II Oefeningensessies	51
14 Oefeningensessie 1	52
14.1 Oefening 3.6 p85	52
14.2 Voorbeeldexamenvraag	53
14.3 Oefening 3.13 p86	54
15 Oefeningensessie 2	55

15.1 Oefening 6.3 p147	55
15.2 Oefening 8.6 p190	55
15.3 Oefening 9.1 p217	56

Deel I

Theorie

Hoofdstuk 1


Inleiding

1.1 Compilers

Voorbeelden van functies die een statische compiler moet bevatten:

- Broncode omzetten in uitvoerbare fouten:
 - met dezelfde semantiek
 - zo snel mogelijk
 - en/of zo compact, debugbaar, portable, veilig, ... mogelijk
 - en linkbaar.
- Syntaxfouten moeten herkend worden.

1.2 Basiswerking compilers



Figuur 1.1: De basiswerking van een compiler.

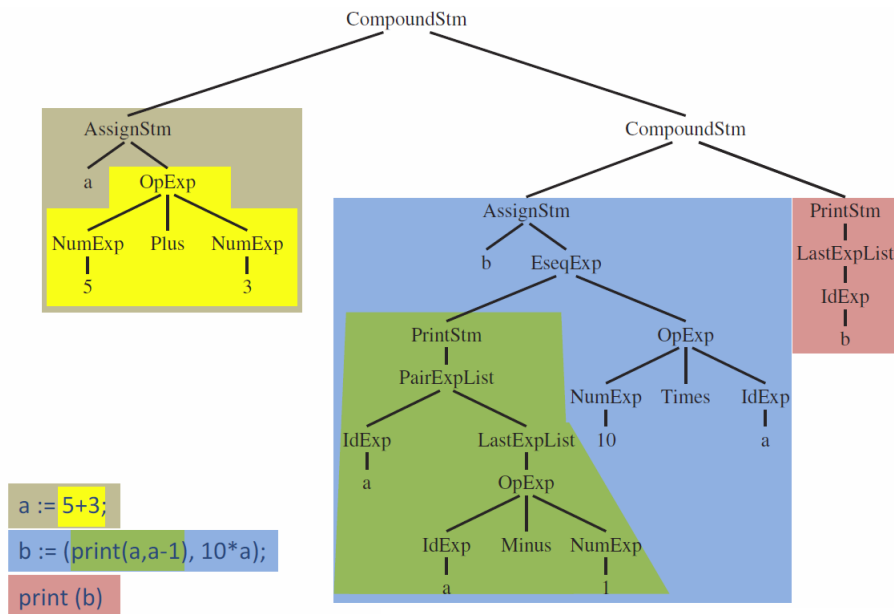
Op figuur 1.1 is de vereenvoudigde basiswerking van een compiler te zien. Een **C** bestand wordt eerst door de compiler front end gestuurd, die het bestand zal omvormen tot een intermediaire representatie. Deze representatie wordt dan door de compiler back end gestuurd om zo assembly of objectcode te genereren. De linker loader zal deze objectcode samenvoegen met eventuele andere libraries om zo een uitvoerbaar programma te hebben.

Q: Waarom wordt de front end en back end opgesplitst?

A: Op die manier is de compiler modulair: Enerzijds moet bij een andere programmeertaal enkel de front end aangepast worden en anderzijds moet bij het wijzigen van de architectuur (de onderliggende processor) enkel de back end aangepast worden.

1.3 Abstract Syntax Tree

De eerste stap van elke compiler is het omvormen van de broncode naar een **Abstract Syntax Tree (AST)**. Veronderstel volgende code, en de daarbijhorende AST die te zien zijn op figuur 1.2. Elke knoop van een AST stelt een bepaalde geldige operatie voor, die afhankelijk is van de gekozen programmeertaal.



Figuur 1.2: De boomvoorstelling van een eenvoudig, lusloos programma. De gekleurde deelbomen komen overeen met de gekleurde segmenten in de code zelf. Als toekenningsoperator wordt er gekozen voor `:=` dat vanaf nu als één geheel moet beschouwd worden.

1.3.1 Contextvrije grammatica's

Om een AST op te stellen moet de notie van **tokens** ingevoerd worden. Een token is eenvoudig gezien een bepaald symbool dat een betekenis heeft. De tokens van de code uit figuur 1.2 zijn te zien in tabel 1.1. Uit de theorie van de generatieve grammatica's weten we dat er zowel terminale als niet-terminale tokens bestaan:

- **Terminale tokens** zijn symbolen die een blad voorstellen in de AST. Deze tokens hebben als eigenschap dat ze geen verdere tokens kunnen genereren en vormen dan ook het alfabet van het programma.
- **Niet-terminale tokens**, kortweg niet-terminalen genoemd, zijn de regels die de taal definiëren en zijn de niet-bladeren van de AST. Niet-terminalen hebben als eigenschap dat ze letters van het alfabet kunnen genereren.

symbolen(ascii)	token	waarde
a	id	string a
:=	:=	
5	num	integer 5
+	+	
3	num	integer 3
;	;	
b	id	string b
((
print	print	
-	-	
*	*	
	whitespace	

Tabel 1.1: De tokens die voorkomen uit het programma van figuur 1.2

Op figuur 1.3 zijn een aantal terminalen en niet-terminalen te zien. De niet-terminale token *CompoundStm* bestaat bijvoorbeeld uit twee *Stm* tokens, gescheiden door een punt komma. Deze twee *Stm* tokens kunnen in deze vereenvoudigde programmeertaal enkel een *AssignStm* of *PrintStm* zijn. Bij *AssignStm* wordt er een terminale token verwacht in de vorm van een variabele identifier, gevolgd door de toekenningsoperator en een *Exp* token. Enkel deze *Exp* kan nog vier vormen aanneemen: *IdExp*, *NumExp*, enz... Dit wordt uitgewerkt voor de eerste toekenningsoperatie uit figuur 1.2 en

$Stm \rightarrow Stm ; Stm$	(CompoundStm)	$ExpList \rightarrow Exp . ExpList$	(PairExpList)
$Stm \rightarrow id := Exp$	(AssignStm)	$ExpList \rightarrow Exp$	(LastExpList)
$Stm \rightarrow print (ExpList)$	(PrintStm)	$Binop \rightarrow +$	(Plus)
$Exp \rightarrow id$	(IdExp)	$Binop \rightarrow -$	(Minus)
$Exp \rightarrow num$	(NumExp)	$Binop \rightarrow \times$	(Times)
$Exp \rightarrow Exp Binop Exp$	(OpExp)	$Binop \rightarrow /$	(Div)
$Exp \rightarrow (Stm , Exp)$	(EseqExp)		

Figuur 1.3: De rood omkaderde symbolen zijn terminalen terwijl de blauw omkaderde niet-terminalen zijn.

is te zien op figuur 1.4.

1.3.2 Opbouw AST

Een AST kan nu **bottom-up** opgemaakt worden door volgende procedure uit te voeren:

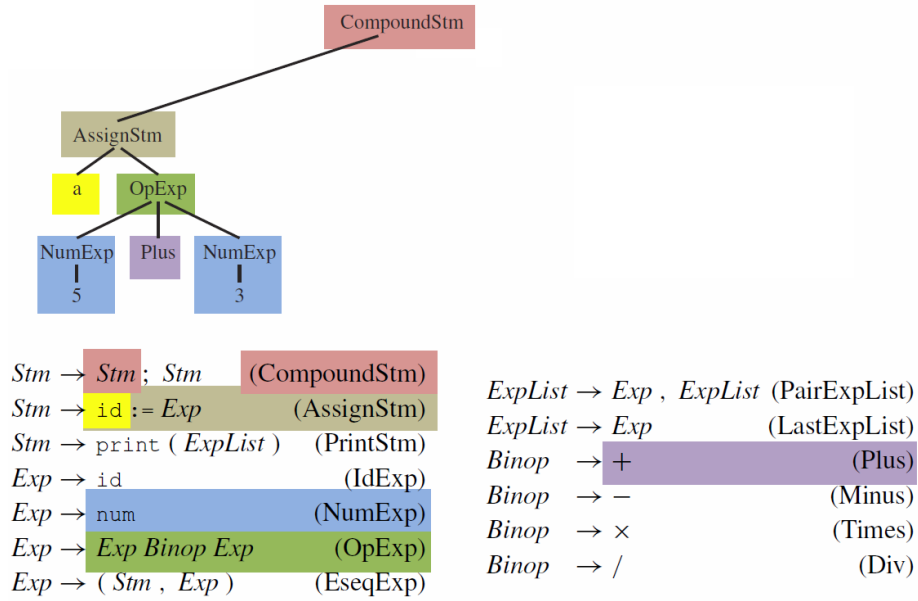
1. Voor elke mogelijke knoop moet er een struct gemaakt worden zoals bijvoorbeeld:

A_stm_ A_exp_ A_expList_

2. Elke struct moet bestaan uit

- een enum voor het precieze token te bepalen,
- een union voor de verschillende combinaties van tokens in het rechter lid en,
- pointers naar kindknoepen.

Dit wordt geïllustreerd in code 1.1.



Figuur 1.4: Illustratie van contextvrije grammatica op de eerste toekenningsoperatie uit figuur 1.2.

```

typedef char * string;
typedef struct A_stm_ * A_stm;
typedef struct A_exp_ * A_exp;
typedef struct A_expList_ * A_expList;

struct A_stm_ {
    enum {A_compoundStm, A_assignStm, A_printStm} kind;
    union {
        struct {A_stm stm1, stm2;} compound;
        struct {string id; A_exp exp;} assign;
        struct {A_expList exps;} print;
    } u;
};

```

Code 1.1: Voorbeeld van een struct voor een AST.

3. In de constructor worden de knopen aangemaakt, zoals te zien in code 1.2.

```

A_stm A_CompoundStm(A_stm stm1, A_stm stm2){
    A_stm s = malloc(sizeof(*s));
    s->kind = A_compoundStm;
    s->u.compound.stm1 = stm1;
    s->u.compound.stm2 = stm2;
    return s;
}

```

Code 1.2: Voorbeeld van een constructor voor een AST.

Op deze manier zou de boom uit figuur 1.2 hardgecodeerd kunnen worden, wat natuurlijk geen goede manier is. Het is de taak van een lexer en parser om de constructie van een AST te automatiseren, die respectievelijk in hoofdstuk 2 en 3 behandeld worden.

1.3.3 Interpreter

Uit een AST kan een eenvoudige interpreter geschreven worden. Dit stuk is informatief, en wordt niet gevraagd op het examen.

- Door de boom postorder diepte-eerst te overlopen, wordt de boom in de juiste manier behandeld.
- Het bijhouden van de waarden van variabelen kan via een gelinkte lijst:

```
typedef struct table * Table_;
struct table {string id; int value; Table_ tail;};
Table_ Table(string id; int value; Table_ tail) {
    Table_ t = malloc(sizeof(*t));
    t->id = id;
    t->value = value;
    t->tail = tail;
    return t;
}
```

- Stel nu dat dit de eerste drie regels van een programma zijn:

```
a := 2;
b := 3;
a := 3;
```

- Voor de eerste toekenning bevat de gelinkte lijst slechts één knoop met als sleutel *a* en waarde *2*.
- Bij de tweede toekenning wordt de originele gelinkte lijst meegegeven via de variabele *tail*. Na deze constructor zal de gelinkte lijst twee knopen bevatten.
- Na deze constructor bevat de gelinkte lijst drie knopen. Merk op dat er twee knopen zijn met sleutel *a*, maar dat ze elk een verschillende waarde hebben. Aangezien een nieuwe knoop vooraan wordt toegevoegd, zal de interpreter enkel de meest recentste waarde opvragen.

Hoofdstuk 2

Lexicale Analyse

2.1 Lexicale tokens

- Herkennen van een reeks opeenvolgende karakters die een geheel vormen volgens de syntax van een programmeertaal, zoals o.a:
 - sleutelwoorden: int, float, for, new, ...
 - identifiers: foo, n14, variabelenaam
 - getallen: -37, 0x16L, 10.4, ...
 - operatoren: +, -, *, &, &&, ...
 - andere tokens: { } "; /* */ / () []

- Veronderstel volgende code:

```
float match0(char * s) { /* find a zero */
    if (!strcmp(s, "0.0", 3))
        return 0.;
}
```

, dan worden volgende tokens gegenereerd, waarbij dat sommige tokens een **attribuut** hebben:


```
FLOAT ID(match0) LPAREN CHAR START ID(s) RPAREN LBRACE IF LPAREN BANG ID(strncmp)
LPAREN ID(s) COMMA STRING(''0.0'') COMMA NUM(3) RPAREN RPAREN RETURN REAL(0.0)
SEMI RBRACE EOF
```

2.2 Eindige automaten

- Er wordt met reguliere expressie gewerkt om te omschrijven welke karaktersequentie met een bepaald token overeenstemmen:

<i>if</i>	{return IF;}
$[a - z][a - z0 - 9]^*$	{return ID;}
$[0 - 9]^+$	{return NUM;}
$([0 - 9]^+ \mid "." [0 - 9]^*) ([0 - 9]^+ \mid "." [0 - 9]^+)$	{return REAL;}

Tabel 2.1: Reguliere expressies voor een aantal tokens.

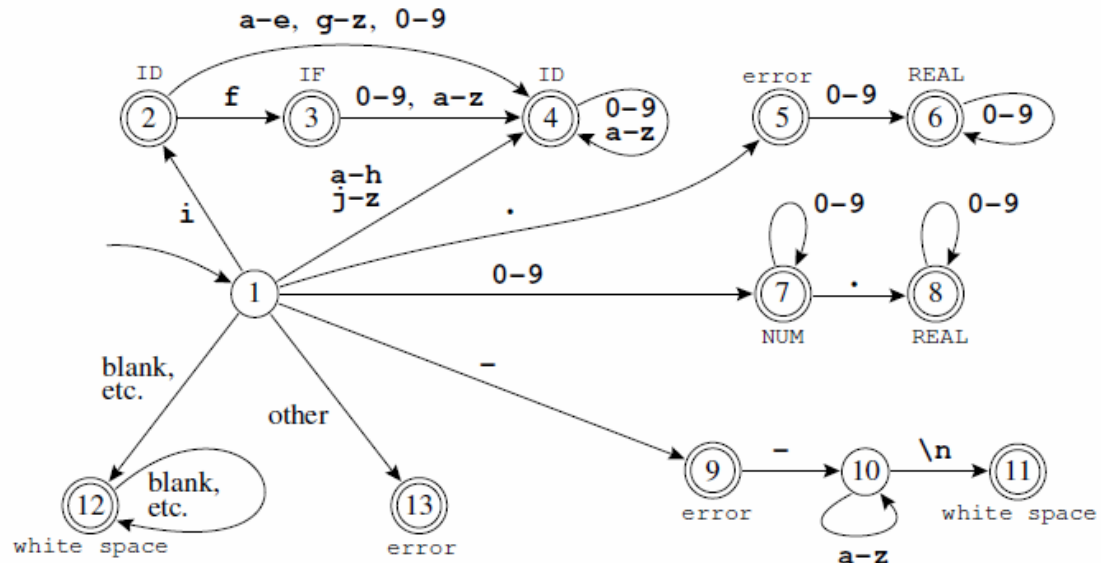


Figuur 2.1: Eindige automaten voor lexicale tokens.

- Met behulp van de constructie van Thompson kan een **niet-deterministische automaat (NFA)** opgebouwd worden uit een reguliere expressie. Op figuur 2.1 zijn de eindige automaten te zien van de reguliere expressies uit tabel 2.1.
- Deze individuele automaten kunnen samengevoegd worden tot een gecombineerde automaat, te zien op figuur 2.2

In dit geval is de gecombineerde automaat al een **deterministische eindige automaat (DFA)** aangezien elke mogelijke staat slechts één transitie heeft voor elke input. Het doel van lexicale analyse is om een DFA op te stellen zodat de tokens op een efficiënte manier kunnen bepaald worden. Een DFA wordt doorgaans geïmplementeerd als een transitietabel:

```
int edges[][256] = { /* ... 0 1 2 ... - ... e f g h i j ... */
/* state 0 */      { ... 0 0 0 ... 0 ... 0 0 0 0 0 0 ... },
/* state 1 */      { ... 7 7 7 ... 9 ... 4 4 4 4 2 4 ... },
/* state 2 */      { ... 4 4 4 ... 0 ... 4 3 4 4 4 4 ... },
/* state 3 */      { ... 4 4 4 ... 0 ... 4 4 4 4 4 4 ... },
/* state 4 */      { ... 4 4 4 ... 0 ... 4 4 4 4 4 4 ... },
/* state 5 */      { ... 6 6 6 ... 0 ... 0 0 0 0 0 0 ... },
/* state 6 */      { ... 6 6 6 ... 0 ... 0 0 0 0 0 0 ... },
/* state 7 */      { ... 7 7 7 ... 0 ... 0 0 0 0 0 0 ... },
/* state 8 */      { ... 8 8 8 ... 0 ... 0 0 0 0 0 0 ... },
/* ... */
};
```




Figuur 2.2: Combinatie van eindige automaten.

2.3 Opbouw deterministische eindige automaat


- We starten met een reguliere expressie, die een bepaald token voorstelt:

$$(aaa)^* | (aa)^*$$

- Zoals vermeld zal de constructie van Thompson een niet-deterministische automaat aanmaken van een bepaalde reguliere expressie. Er bestaat de kans dat deze automaat deterministisch is, maar dat is niet altijd zo. In het geval van bovenstaande reguliere expressie ziet de automaat er uit zoals op figuur 2.3 of figuur 2.4.



Figuur 2.3: Een niet-deterministische eindige automaat.



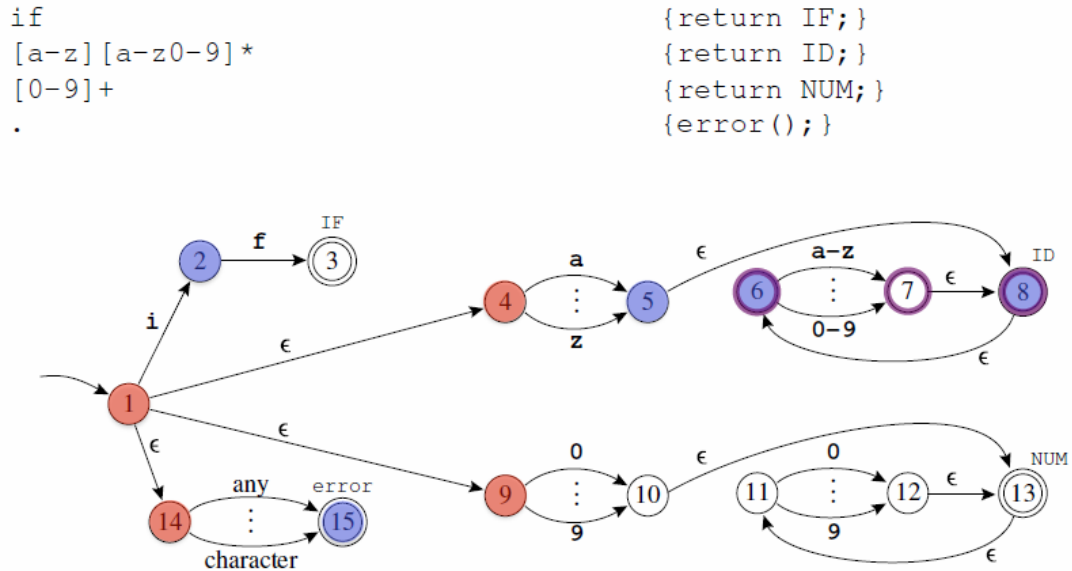
Figuur 2.4: Een niet-deterministische eindige automaat waarbij de eerste transitie kan gebeuren zonder een symbool te verwerken.

Welke richting moeten we nu uit bij `aaaaaaaa` voor de eerste `a`? Bij een niet-deterministische automaat moeten we gokken welke de juiste zal zijn.

- Gelukkig kan ook een DFA opgebouwd worden uit een NFA via de deelverzamelingconstructie. Op die manier kan een DFA opgebouwd worden door (i) enkel de reguliere expressies handmatig

te definiëren, (ii) algoritmisch deze reguliere expressies om te vormen tot een NFA, en (iii) algoritmisch deze NFA om te vormen tot een DFA.

- Veronderstel de reguliere expressies en de daarbijhorende NFA in figuur 2.5.




Figuur 2.5: Een aantal reguliere expressies en de daarbijhorende NFA.

Stel dat we nu de string *in* moeten checken:

1. Zonder teken op te eten kunnen we in 1 komen en in zijn ϵ -closure: $\{1, 4, 9, 14\}$.
2. Vanuit $\{1, 4, 9, 14\}$ kunnen we voor *i* naar $\{2, 5, 6, 8, 15\}$.
3. Vanuit $\{2, 5, 6, 8, 15\}$ kunnen we voor *n* naar $\{6, 7, 8\}$.
4. Daarvan is 8 een aanvaardingstoestand voor ID.

Op die manier bekommen we de DFA uit figuur 2.6.



Figuur 2.6: De NFA uit figuur 2.5 geconverteerd naar een DFA.

2.3.1 Conversie NFA naar DFA

- Drie functies:

1. **edge(s, c)** = alle NFA staten bereikbaar uit toestand s over pijlen met transitiesymbool c .
2. **closure(S)** = de kleinste verzameling T voor een subset S waarvoor geldt:

$$T = S \cup \left(\bigcup_{s \in T} \text{edge}(s, \epsilon) \right)$$

Q: Waarom moet dit de kleinste verzameling zijn?

A: De volledige verzameling van toestanden voldoet ook aan deze vergelijking, en dat is een triviaal geval.

Via iteratie kan T berekent worden:

```

T ← S
repeat
  T' ← T
  T ← T' ∪ (⋃s ∈ T' edge(s, ε))
until T = T'
```

- Dit is een voorbeeld van een fixpoint algoritme. Dit wil zeggen dat uiteindelijk $f(x) = x$ geldig is. In het voorbeeld van de functie **closure(S)**, hier genoteerd als **F(x)**, is dit zeker waar:

$$\begin{aligned}
 F(\epsilon) &= S \\
 F(S) &= \dots \\
 F(F(S)) &= \dots \\
 &\dots \\
 F(F(F(\dots))) &= T \\
 F(T) &= T
 \end{aligned}$$

- Aangezien dat uiteindelijk $F(T) = T$ en dat er maar een eindig aantal staten zijn zal het algoritme zeker stoppen.
3. Veronderstel dat we ons bevinden in een set $d = \{s_i, s_k, s_l\}$ van NFA staten s_i, s_k en s_l . Startend vanuit d en het symbool c , bekomen we een nieuwe set van NFA staten:

$$\mathbf{DFAedge(D, c)} = \mathbf{closure} \left(\bigcup_{s \in D} \text{edge}(s, c) \right)$$

Via deze functie, de startstaat s_1 en input string c_1, \dots, c_k kan de NFA simulatie als volgt geschreven worden:

```

d ← closure({s1})
for i ← 1 to k
  d ← DFAedge(d, ci)
```

- De combinatie van deze drie functies leiden tot het algoritme om een NFA om te zetten naar een DFA:

```

states[0] ← {};
states[1] ← closure({s1});
p ← 1;    j ← 0;
```



```

while  $j \leq p$ 
  foreach  $c \in \Sigma$ 
     $e \leftarrow \text{DFAedge}(\text{states}[j], c)$ 
    if  $e == \text{states}[i]$  for some  $i \leq p$ 
      then  $\text{trans}[j, c] \leftarrow i$ 
    else  $p \leftarrow p + 1$ 
       $\text{states}[p] \leftarrow e$ 
       $\text{states}[j, c] \leftarrow p$ 
   $j \leftarrow j + 1$ 

```

De gegenereerde DFA is suboptimaal: vanuit sommige toestanden worden identiek dezelfde strings aanvaard. Volgende optimalisaties kunnen nog doorgevoerd worden:

- Knopen samenvoegen waarvoor geldt dat

$$\forall c \in \Sigma : \text{trans}[s_1, c] = \text{trans}[s_2, c]$$

- Staten s_1 en s_2 zijn equivalent als ze beiden niet finaal of finaal zijn voor dezelfde tokens.

Hoofdstuk 3

Parsing

3.1 Inleiding

Het basisidee van parsing is om een string van tokens te analyseren en kijken of deze syntactisch geldig zijn.

Q: Waarom gaan we context-vrije grammatica gebruiken in plaats van reguliere expressies om de tokens van een lexer te parsen?

A: Reguliere expressies kan geen recurse uitdrukken. Ook kan de eis voor gebalanceerde haakjes niet uitgedrukt worden met reguliere expressies.

3.2 Context-vrije grammatica

- Een **taal** is een verzameling **strings**.
- Een **string** is een eindige sequentie **symbolen** uit een **alfabet**.
- Analogie met een parser:
 - De broncode levert de strings op via lexicale analyse.
 - De lexicale tokens zijn de symbolen.
 - Het alfabet is de verzameling tokentypes die gegenereerd worden door de lexicale analyzer.
- De taal van een context-vrije
- Context-vrije grammatica definieert de **syntax** van de taal.

3.2.1 Afleiden van een zin

Grammatica 3.1 toont een voorbeeldsyntax voor lusloze programma's. Een voorbeeld van een zin is:

$$\text{id} := \text{num} ; \text{id} := \text{id} + (\text{id} := \text{num} + \text{num}, \text{id}) \quad (3.1)$$

die bijvoorbeeld afgeleidt is door de lexer van:

$$\text{a} := 7; \text{b} := \text{c} + (\text{d} := 5 + 6, \text{d})$$

1	$S \rightarrow S ; S$	4	$E \rightarrow \text{id}$		
2	$S \rightarrow \text{id} := E$	5	$E \rightarrow \text{num}$	8	$L \rightarrow E$
3	$S \rightarrow \text{print} (L)$	6	$E \rightarrow E + E$	9	$L \rightarrow L , E$
		7	$E \rightarrow (S , E)$		

Grammatica 3.1: Een syntax voor een lusloos programma.

Het afleiden van een zin start altijd met een **startsymbol**, die twee vormen kan aannemen:

1. Het startsymbool kan enerzijds het eerste symbool zijn.
2. Anderzijds wordt het startsymbool expliciet aangeduid zoals bijvoorbeeld $P \rightarrow S\$$, met \$ het stopsymbool.

```

S
S ; S
S ; id := E
id := E ; id := E
id := num ; id := E
id := num ; id := E + E
id := num ; id := E + (S, E)
id := num ; id := id + (S, E)
id := num ; id := id + (id := E, E)
id := num ; id := id + (id := E + E, E)
id := num ; id := id + (id := E + E, id)
id := num ; id := id + (id := num + E, id)
id := num ; id := id + (id := num + num, id)

```

Code 3.1: Het afleidingsproces.

Code 3.1 toont een illustratie van hoe het afleidingsproces te werk gaat, toegepast op voorbeeldzin 3.1. Bij elke iteratie wordt het niet-terminale token dat onderlijnt is verwerkt.

Q: Is dit een linkse of een rechtse afleiding?


A: Geen van beide, omdat er gekozen kan worden om zowel de meest linkse als de meest rechtse token te verwerken.

Figuur 3.2 toont de bijhorende parse tree. Hier zijn de bladeren ook een verzameling van terminale tokens. De taak van een parser is om de bijhorende boom op te stellen, uitgaande van enkel de bladeren.


3.2.2 Ambigue grammatica

Q: Stel dat we Grammatica 3.1 hebben. Wat gebeurt er voor het statement (zonder rode of blauwe haakjes) $a := (x + (y) + z)$?

A: Dit is een voorbeeld van een ambigue grammatica. Aan de hand van de grammatica is het onmogelijk om slechts één parse tree op te bouwen. Figuur 3.3 toont beide parse trees voor het statement. Bij de linkse boom worden de rode haakjes gebruikt terwijl bij de rechtse boom de blauwe haakjes gebruikt worden.



Figuur 3.2: De bijhorende parse tree voor voorbeeldzin 3.1.

Figuur 3.3: Voor Grammatica 3.1 kunnen er twee parse trees opgebouwd worden voor het statement `a := x + y + z.`

Bij een plus-operatie is dit niet heel belangrijk aangezien het toch associatief is, maar bij niet-associatieve operaties is dit duidelijk niet goed.

3.2.3 Grammatica disambiguëren

Een grammatica hoeft niet perse de regels van de wiskunde te volgen. Daarom is het automatiseren ook moeilijk, omdat het afhangt van welke semantiek gewenst is. Er kan bijvoorbeeld gesteld worden dat:

- $*$ en $/$ voorrang heeft op $+$ en $-$,
- $a + b + c = (a + b) + c$, dus $+$ is links associatief.

Om dit te realiseren worden er **termen** en **factoren** ingevoerd. Op die manier kan Grammatica 3.4 omgevormd worden tot 3.5.

$$\begin{aligned} E &\rightarrow \text{id} \\ E &\rightarrow \text{num} \\ E &\rightarrow E * E \\ E &\rightarrow E / E \\ E &\rightarrow E + E \\ E &\rightarrow E - E \\ E &\rightarrow (E) \end{aligned}$$

Grammatica 3.4: Een ambigue grammatica. Hier wordt de regel dat $*$ en $/$ voorrang heeft op $+$ en $-$ niet gerespecteerd.

$E \rightarrow E + T$	$T \rightarrow T * F$	$F \rightarrow \text{id}$
$E \rightarrow E - T$	$T \rightarrow T / F$	$F \rightarrow \text{num}$
$E \rightarrow T$	$T \rightarrow F$	$F \rightarrow (E)$

Grammatica 3.5: Grammatica 3.4 kan hervormt worden, door termen T en factoren F in te voeren. Deze termen dwingen de volgorde van operaties en associativiteit vast.

3.3 Predictive Parsing

Sommige grammatica's kunnen eenvoudig geparsed worden met een **recursive descent parser**. Voor elke niet-terminal is er een overeenkomstige functie. In elke functie is er een switch clause voor elke productieregel die door de niet-terminal kan gegenereerd worden. Niet-terminals worden recursief aangeroepen terwijl terminals verwerkt worden.

Code 3.2 toont een voorbeeld van zo een recursive descent parser toegepast op Grammatica 3.6.

$S \rightarrow \text{if } E \text{ then } S \text{ else } S$	$L \rightarrow \text{end}$
$S \rightarrow \text{begin } S L$	$L \rightarrow ; S L$
$S \rightarrow \text{print } E$	$E \rightarrow \text{num} = \text{num}$

Grammatica 3.6

```
enum token {IF, THEN, ELSE, BEGIN, END, PRINT, SEMI, NUM, EQ};
extern enum token getToken(void);

enum token tok;
void advance() {tok = getToken();}
void eat(enum Token t) {if (tok==t) advance(); else error();}

void S(void) {switch(tok){
    case IF:    eat(IF); E(); eat(THEN); S(); eat(ELSE); S(); break;
    case BEGIN: eat(BEGIN); S(); L(); break;
    case PRINT: eat(PRINT); E(); break;
    default:    error();
}}

void L(void) {switch(tok){
    case END:    eat(END); break;
    case SEMI:   eat(SEMI); S(); L(); break;
    default:    error();
}}

void E(void) {
    eat(NUM) ; eat(EQ) ; eat(NUM);
}
```

Code 3.2: Een recursive descent parser gebaseerd op Grammatica 3.6

Een recursive descent parser werkt enkel als het eerste terminale symbool van een subexpressie genoeg informatie oplevert.

3.3.1 First and follow sets

Om de begrippen **first set** en **follow set** uit te leggen wordt Grammatica 3.7 gebruikt.

$Z \rightarrow d$	$Y \rightarrow$	$X \rightarrow Y$
$Z \rightarrow X Y Z$	$Y \rightarrow c$	$X \rightarrow a$

Grammatica 3.7

- **nullable**(X) \rightarrow boolean: true als X de lege string kan afleiden.

We zien dat $\text{nullable}(Y)$ zeker waar is voor Grammatica 3.7. We kunnen echter vanuit X ook naar de lege string gaan via $X \rightarrow Y \rightarrow \epsilon$, maar niet vanuit Z .

	nullable	FIRST	FOLLOW
X	yes		
Y	yes		
Z	no		

- **FIRST(γ)**: verzameling terminals waarmee strings kunnen beginnen die van expressie γ kunnen afgeleid worden.

Uitgewerkt voor de drie startsymbolen:

X : Vanuit X zijn er twee mogelijkheden: $X \rightarrow a$ en $X \rightarrow Y$. We zien dat a een terminal is dus die behoort al zeker tot de FIRST set. Vanuit Y kan ook nog de lege string en c bereikt worden. Hieruit volgt $\text{FIRST}(X) = \{a\ c\}$.

Y : Vanuit Y kan enkel c bereikt worden: $\text{FIRST}(Y) = \{c\}$.

Z : In eerste instantie kan Z direct d bereiken, dus die zit zeker in de FIRST set. Aangezien ook de productieregel $Z \rightarrow X\ Y\ Z$ bestaat en zowel X als Y nullable zijn, kan zowel de FIRST set van X als van Y overgenomen worden.

$\text{FIRST}(Z) = \{a\ c\ d\}$

	nullable	FIRST	FOLLOW
X	yes	a c	
Y	yes	c	
Z	no	a c d	

- **FOLLOW(X)**: is de verzameling van terminals t die meteen op X kunnen volgen, dus waarvoor de afleiding X_t bestaat.

Algoritme 3.3 is een fixpoint algoritme die de first, follow en nullable berekent.

```

for each terminal symbol  $Z$ 
   $\text{FIRST}[Z] \leftarrow \{Z\}$ 
repeat
  for each production  $X \rightarrow Y_1 Y_2 \dots Y_k$ 
    for each  $i$  from 1 to  $k$ , each  $j$  from  $i+1$  to  $k$ ,
      if all the  $Y_i$  are nullable
        then  $\text{nullable}[X] \leftarrow \text{true}$ 
      if  $Y_1 \dots Y_{i-1}$  are all nullable
        then  $\text{FIRST}[X] \leftarrow \text{FIRST}[X] \cup \text{FIRST}[Y_i]$ 
      if  $Y_{i+1} \dots Y_k$  are all nullable
        then  $\text{FOLLOW}[Y_i] \leftarrow \text{FOLLOW}[Y_i] \cup \text{FOLLOW}[X]$ 
      if  $Y_{i+1} \dots Y_{j-1}$  are all nullable
        then  $\text{FOLLOW}[Y_i] \leftarrow \text{FOLLOW}[Y_i] \cup \text{FIRST}[Y_j]$ 
until FIRST, FOLLOW and nullable did not change in this iteration

```

Code 3.3: Iteratieve berekening van FIRST, FOLLOW en nullable

3.3.2 Opstellen Predictive Parsing Tabel

Uitbreiden definitie van first naar strings:

- $\text{FIRST}(W\gamma) = \text{FIRST}(W)$ als niet nullable(W)
- $\text{FIRST}(W\gamma) = \text{FIRST}(W) \cup \text{FIRST}(\gamma)$

Er zijn drie gevallen waarbij er twee keuzes zijn. Moeten we $X \rightarrow a$ of $X \rightarrow Y$ nemen? De string d levert minstens twee parse tree op. De grammatica was zelfs ambigu. Dit kan nooit geparsed worden.

3.3.3 LL(1) Parsers

- Elk vak in de tabel bevat slechts 1 productieregel.
- Left-to-right parse: begin vooraan in broncode en verwerk van links naar rechts.
- Leftmost-derivation:
- 1-symbol lookahead: Er wordt slechts één symbool vooraf bekeken.
- $\text{LL}(k)$:
 - k symbolen vooraf bekijken. De first sets bevatten sequenties van k terminals.
- ! Mogelijke problemen:
 - Linkse recursie.
 - ◇ Probleem: zekerheid van meerdere productieregels in een vak want $\text{FIRST}(T) \in \text{FIRST}(E - T)$.
 - ◇ Oorzaak: E verschijnt links in de rechterkant van een E -productie.
 - ◇ Oplossing:
 - Linkse factorisatie.
 - ◇ Probleem: De parser kan geen onderscheid maken tussen twee gelijkaardige strings.
 - ◇ Oplossing: grammatica herschrijven.
- Error recovery is mogelijk.
- ! Beslissing nemen na k symbolen blijft een zwakte.

3.3.4 Error Recovery

Probleem: pseudocode voor error. We willen geen compiler die geen nuttige foutboodschappen kan geven. Compiler mag ook niet stoppen bij eerste fout, omdat meerdere fouten nog verder kunnen voorkomen.

- Gewoon een print statement = vrij slechte methode aangezien er geen tokens opgegeten worden. De parser doet voort alsof hij F en T_{prime} al geparsed heeft. De parser komt in foute toestand.
- Print statement combineren met de skipto functie, die tokens zal opeten totdat er een token tegenkomt die in de follow set zit. Alle karakters die niet in de follow zitten, zal nog deel uitmaken van de subexpressie.

3.4 LR(k) parser

- Left-to-right parse.
- Rightmost-derivation.
- k -token lookahead.
- Werkt met een inputstroom en een stapel.
- Twee mogelijke acties:
 - **Shift:** verplaats een token van de inputstroom op een stapel.
 - **Reduce:** kies een regel $X \rightarrow ABC$; Stel dat de stapel $[C, B, A]$ bevat, kunnen deze alle drie gepopt en vervangen worden door X .
- Toestandsautomaat:
 - Stapel houdt token bij en toestand.
 - Toestand en k lookahead symbolen in de input bepalen de volgende actie.
 - Implementeren aan de hand van een toestandstransitietabel.

3.5 Local Error Recovery

Hoofdstuk 4

Abstracte syntax

Abstract syntax tree stelt eerder semantiek voor, parse trees de constructieregels. De abstract syntax tree wordt opgebouwd tijdens het parsen.

4.1 Semantische acties

Een parser voert syntactische acties uit zoals shift en reduce. Een semantische actie heeft betrekking tot de betekenis van de expressies. Een aantal voorbeelden van het bepalen van semantische waarden:

- Het type van het linkerlid bepalen van de expressie $a = 5 + 3$.
- Terminals en niet-terminals hebben semantische waarden van een bepaald type.

In een recursive-descent parser zijn de semantische acties de returnwaarden van de parsingfunctie. Voor elke terminaal en niet-terminaal symbool, wordt er een **type** geassocieerd van semantische waarden. Een eenvoudige rekenmachine wordt kan op deze manier *geïnterpreteerd* worden, uitgewerkt op grammatica 4.1 in code 4.1.

$$\begin{array}{lll} S \rightarrow E \$ & T \rightarrow F T' & F \rightarrow \text{id} \\ E \rightarrow T E' & T' \rightarrow * F T' & F \rightarrow \text{num} \\ E' \rightarrow + T E' & T' \rightarrow / F T' & F \rightarrow (E) \\ E' \rightarrow - T E' & T' \rightarrow & \\ E' \rightarrow & & \end{array}$$

Grammatica 4.1

```
enum token {EOF, ID, NUM, PLUS, MINUS, ...};
union tokenval {string id; int num; ...};
```

```

enum token tok;
union tokenval tokval;

int lookup(string id) { ... }

void eatOrSkipTo(int expected, int* stop){
    if (tok == expected) eat (expected);
    else {printf(...); skipto(stop)}
}

int F_follow[] = { PLUS, TIMES, RPAREN, EOF, -1 };
int F(void) {switch (tok) {
    case ID:      {int i = lookup(tokval.id); advance(); return i;}
    case NUM:     {int i = tokval.num; advance(); return u;}
    case LPAREN:  eat(LPAREN); int i = E(); eatOrSkipTo(RPAREN, F_follow);
                  return i; }
    case EOF:
    default:      printf("expected ID, NUM, or left-paren");
                  skipto(F_follow);
                  return 0;
}}

int T_follow[] = { PLUS, RPAREN, EOF, -1 };
int T(void) {switch (tok) {
    case ID: case NUM: case LPAREN: return Tprime(F());
    default: printf("expected ID, NUM, or left-paren");
              skipto(T_follow);
              return 0;
}}

int Tprime(int a) {switch (tok) {
    case TIMES: eat(TIMES); return Tprime(a*F());
    case PLUS: case RPAREN: case EOF: return a;
    default: ...
}}

```

Code 4.1: Recursive-descent parser voor grammatica 4.1.

De tokens ID en NUM moeten respectievelijk waarden van type `string` en `int` bevatten. De functie `lookup` kan een waarde zoeken voor een identifier. Zowel `E`, `T` als `F` is van type `int`.

In plaats van dit handmatig te doen, kan een tool gebruikt worden die dit genereert zoals Yacc (look ahead left-to-right parser generator), zoals te zien in code 4.2.

```

%{ declarations of yylex and yyerror %}
%union {int num; string id;}
%token <num> INT
%token <id> ID
%type <num> exp
%start exp

%left PLUS MINUS
%left TIMES
%left UMINUS
%%

```

```

exp : INT                {$$ = $1;}
    | exp PLUS exp       {$$ = $1 + $3;}
    | exp MINUS exp      {$$ = $1 - $3;}
    | exp TIMES exp      {$$ = $1 * $3;}
    | MINUS exp          %prec UMINUS {$$ = - $2;}

```

Code 4.2: Yacc.

Figuur 4.2 toont een LR parse of een string, gebruik makend van code 4.2.

<i>Stack</i>		<i>Input</i>	<i>Action</i>
		1 + 2 * 3 \$	<i>shift</i>
1		+ 2 * 3 \$	<i>reduce</i>
INT			
1		+ 2 * 3 \$	<i>shift</i>
exp			
1		2 * 3 \$	<i>shift</i>
exp	+		
1		* 3 \$	<i>reduce</i>
exp	+	INT	
1		* 3 \$	<i>shift</i>
exp	+	exp	
1		3 \$	<i>shift</i>
exp	+	exp	*
1		\$	<i>reduce</i>
exp	+	exp	*
1		\$	<i>reduce</i>
exp	+	exp	*
1		\$	<i>reduce</i>
exp	+	6	
1		\$	<i>reduce</i>
7		\$	<i>accept</i>
exp			

Figuur 4.2: Parsen met een semantische stack.

Interpreteren met behulp van semantische acties is dus zeer haalbaar. In feite kan compilatie ook uitgevoerd worden met semantische acties, maar wordt in de praktijk afgeraden:

- Analyse kan enkel uitgevoerd worden in de volgorde waarin de inputstream geparsed wordt.
- Code wordt gegenereerd op basis van de parse tree, maar zo een tree is niet geschikt. Er zit te veel nutteloze informatie in zoals de `:=` operator, en dient eerder om de syntax uit te drukken en niet de semantiek.

4.2 Abstract Parse Tree Construction

$S \rightarrow S ; S$	$L \rightarrow$
$S \rightarrow \text{id} := E$	$L \rightarrow L E$
$S \rightarrow \text{print } L$	
$E \rightarrow \text{id}$	$B \rightarrow +$
$E \rightarrow \text{num}$	$B \rightarrow -$
$E \rightarrow E B E$	$B \rightarrow \times$
$E \rightarrow S , E$	$B \rightarrow /$

[h]

Grammatica 4.3

In principe Grammatica 4.5 is ambigue. Binaire operator specificeert geen associativiteit. Dit is geen probleem, aangezien de parser dit al beslist heeft. Dus de grammatica die de parser gebruikt mag niet ambigue zijn, wel die van de abstract syntax tree, aangezien die dient om de semantiek te definiëren.

4.2.1 Posities

Als je tree opbouwt, wordt deze geanalyseerd om bv types te checken. Bij foutboodschappen moet de compiler weten waar in de inputstroom deze fout gegenereerd wordt. Er kan een **positiestack** bijgehouden worden die de positie van elke token bevat.

Hoofdstuk 5

Semantische analyse

Semantische analyse is het proces van een compiler dat:

- definities van variabelen mapt op hun waarden,
- controleert dat elke expressie een correct type heeft,
- de abstract syntax tree omvormt zodat deze bruikbaar wordt om machinecode te genereren.

5.1 Symbooltabellen

```
int b = 0;
extern int a;
void foobar(float b){
    if(b == 0.0){
        char * b = malloc(1);
        *b = 0;
    }
}
```

Code 5.1: Het scopeprobleem.

In code 5.1 wordt er een nullbyte weggeschreven naar b . Is dit een string, float, 32 bit integer, 64 bit integer? Het algemene probleem is dat er verschillende scopes zijn, en binnen elke scope kan dezelfde variabele identifier gebruikt worden. Via **symbooltabellen** wordt dit efficiënt opgelost. Een symbooltabel bestaat uit een **omgeving** σ_i en een verzameling **bindings**:

$$\sigma_1 = \{g \mapsto \text{string}, a \mapsto \text{int}\}$$

Elke environment σ_i bestaat uit de samenstelling van zijn specifieke bindings en eventueel de bindings van andere σ_j voor $j \neq i$. De specifieke bindings van σ_i hebben voorrang op de bindings van σ_j .

De omgevingen kunnen voor de code uit figuur 5.1 gedefinieerd worden als:

bestaande omgeving: σ_0
functiedeclaratie: $\sigma_1 = \sigma_0 + \{a \mapsto \text{int}, b \mapsto \text{int}, c \mapsto \text{int}\}$
regel 3: $\sigma_2 = \sigma_1 + \{j \mapsto \text{int}\}$
regel 4: $\sigma_3 = \sigma_2 + \{a \mapsto \text{string}\}$

```

1      function f(a:int, b:int, c:int) =
2          (print_int(a+c);
3           let var j := a+b
4             var a := "hello"
5             in print(a); print_int(j)
6          end;
7          print_int(b)
8      )

```

Figuur 5.1

! De + operatie is hier niet commutatief. De precieze betekenis hangt af van de scoping regels van een taal.

- Er zijn twee mogelijke implementaties:
 - **Imperatieve implementatie:** Er is slechts één omgeving σ die aangepast wordt naar $\sigma_1, \sigma_2, \dots$ wanneer dit nodig is. Deze **destructieve update** zal σ_1 vernietigen wanneer σ_2 vereist is, maar kan via de **undo stack** terug naar σ_1 gaan. Dit kan bijvoorbeeld geïmplementeerd worden met een hashtable. De operatie $\sigma' = \sigma + \{a \mapsto \tau\}$ wordt geïmplementeerd door de sleutel a met waarde τ toe te voegen aan de hashtable. Om σ te bekomen wordt de sleutel a dan verwijderd. Dit werkt natuurlijk alleen als er toegevoegd wordt op een stacksgewijze manier.
 - **Functionele implementatie:** In deze implementatie wordt de originele σ onaangetast en wordt er een nieuwe datastructuur voor σ' gemaakt. Dit kan ook met hashtabellen geïmplementeerd worden, maar wordt eerder met binaire zoekboomen, eventueel gebalanceerd, geïmplementeerd.

5.1.1 Efficiëntere symbooltabellen

Er zijn een aantal manieren om symbooltabellen te verbeteren:

- In plaats van strings bij te houden in de hashtable of zoekboom kunnen er pointers bijgehouden worden. Dit vermijdt te veel stringoperaties.
- Een andere tabel houdt wel nog deze strings bij, waarnaar kan gerefereerd worden.
- Enkel tijdens het opbouwen van de tabellen wordt er met strings gewerkt.
- Stapel houdt scopes bij en aangemaakte symbolen bij imperatieve tabellen:
 - push `beginScope` bij binnengaan scope.
 - push elk symbool bij declaratie in scope.
 - bij verlaten van de scope: pop tot aan `beginScope`.

5.2 Type Checking

Kijken of de gebruikte veranderlijken:

- gedeclareerd zijn
- ze van het juiste type zijn
- of de types van expressies correct zijn

Door de abstract syntax tree in postorder te overlopen kan dit geïmplementeerd worden. Er zullen altijd eerst declaraties bezocht worden. Er zijn verschillende visitors voor zowel variabelen, expressies als declaraties:

```
struct expty transVar(S_table venv, S_table tenv, A_var v);
struct expty transExp(S_table venv, S_table tenv, A_exp a);
void          transDec(S_table venv, S_table tenv, A_dec d);
struct Ty_ty transTy (                S_table tenv, A_ty a);
```

5.2.1 Expressies

Type Checking expressies wordt uitgevoerd op de abstract syntax tree. Er wordt gekeken of subexpressies het juiste type hebben, en bepalen dan ook het resulterende type.

```
struct expty {Tr_exp exp; Ty_ty ty;};
struct expty expTy(Tr_exp exp, Ty_ty ty) {
    struct expty e; e.exp=exp; e.ty=ty; return e;
}

struct expty transExp(S_table venv, S_table tenv, A_exp a) {
    switch(a->kind) {
        case A_opExp: {
            A_oper oper = a->u.op.oper;
            struct expty left = transExp(venv, tenv, a->u.op.left);
            struct expty right = transExp(venv, tenv, a->u.op.right);
            if (oper == A_plusOp) {
                if(left.ty->kind != Ty_int)
                    EM_error(a->U.op.left->pos, "integer required");
                if(right.ty->kind != Ty_int)
                    EM_error(a->U.op.right->pos, "integer required");
                return expTy(NULL, Ty_int());
            }
        }
    }
}
```

5.2.2 Variabelen

De binding variabelen worden opgezocht in de symbooltabel.

```
struct expty transVar(S_table venv, S_table tenv, A_var v) {
    switch(v->kind) {
```



```

case A_simpleVar: {
    E_entrty x = S_look(venv, v->u.simple);
    if(x && x->kind == E_varEntry)
        return expTy(NULL, actaul_ty(x->u.var.ty));
    else {
        EM_error(v->pos, "undefined variabele %s", S_name(v->u.simple));
        return expTy(NULL, Ty_int());
    }
}
case A_fieldVar: ...
}
}

```

5.2.3 Declaraties

Hoofdstuk 6

Activation Records

Er is een overstap nodig naar een neutrale voorstelling die onafhankelijk is van de oorspronkelijke taal. Er is wel een probleem: zelfs de omzetting van de abstract syntax tree naar deze neutrale voorstelling is afhankelijk van de architectuur waarvoor gecompileerd wordt. Bijvoorbeeld het statement `*p++` in C is anders voor 32-bit of 64-bit systemen. Het doel is om de taalspecifieke Abstract Syntax Tree om te vormen naar een taalonafhankelijke Intermediate Representation Tree.

Bij de meeste talen worden er lokale variabelen gecreëerd bij het aanroepen van een functie. Meerdere instanties van een functie kunnen bestaan en hebben elk hun eigen instanties van lokale variabelen.

```
function f(x: int) : int =  
  let var y := x + x  
  in if y < 10  
      then f(y)  
      else y - 1  
end
```

Een instantie van x wordt aangemaakt elke keer dat f opgeroepen wordt. Door de recursiviteit kunnen er meerdere instanties van x bestaan. Een functieoproep heeft een last-in-first-out (LIFO) gedrag. Alle lokale variabelen binnen een functie worden vernietigd op het moment dat deze functie verlaten wordt. De gebruikte datastructuur is dus een **stack**.

Een hogere orde functie is een functie waarin:

- een andere functie aanwezig is.
- een functie heeft als returnwaarde.
- Voorbeeld:

```
fun f(x) =  
  let fun g(y) = x + y  
      in g  
  end
```

```
val b = f(3)  
val j = f(4)
```

```
val z = h(5)  
val w = j(7)
```

- ✓ Zulke functies worden niet besproken in deze cursus.

6.1 Stack Frames

- Een normale stack kent twee operaties: **push** en **pop**.
- **Problemen:**
 - Lokale variabelen worden in grote hoeveelheden op de stack geplaatst.
 - Lokale variabelen zijn niet altijd geïnitieerd.
 - Ook al zijn de variabelen gepushed, is er nog steeds random access nodig.
- **Oplossing:** De stack als een array beschouwen met een speciaal register - de stack pointer. Elke lokatie na de stack pointer is rommel, alles ervoor is gealloceerd.
- Het gebied op de stack voor een functie f die zijn lokale variabelen, parameters, returnadres en andere temporaries bevat wordt een **activation record** of **stack frame** genoemd.

Wat is het verschil tussen een caller-safed register en een callee-saved register

```

ADD          R1, R2, R3 // R1 = R2 + R3
CALL        F
MUL          R4, R1, R7 // R4 = R1 * R7

```

Gaat F de waarde R1 overschrijven of niet? Als dit onbepaald is het geen geldige code. Een Callee-safed register is de restrictie dat F deze waarde niet mag aanpassen. Een caller-safed register legt de restrictie op aan de caller van F. De assembly moet dan uitgebreid worden:

```

ADD          R1, R2, R3
ST           R1, SP[...] // store R1
CALL        F
LD           R1, SP[...] // load R1
MUL          R4, R1, R7

```

Een deel van de registers worden caller-safed gemaakt, de rest is dan callee-safed. Dit wordt manueel vastgelegd. De compiler kan dan oproepen optimaliseren.


6.1.1 Static Link

De stack kan ook argumenten bevatten die meegegeven worden aan de functie. Een static link is vooral belangrijk bij geneste en recursieve functies. In program 6.3 (slide 6) moet de variabele **output** in elke frame beschikbaar zijn. De static link bevat een pointer naar de buitenste functie, zodat deze variabele in elke geneste functie beschikbaar is.

6.1.2 Escapes

Een variabele *escapes* uit een stack frame als:

- hij passed-by-reference wordt.
- of zijn adres genomen wordt.
- of hij geaccessed wordt vanuit een geneste functie.



Figuur 6.1: Een stack frame.

Een veranderlijke is *memory-resident* (op de stack plaatsen) als

- hij escapet
- of niet in een register past
- of een array is
- of er geen vrij register is

Welke parameters moeten op de stack frame zitten en welke niet? Stel volgende functie:

```
int f(int x, int y){
    f(x);
    g(&x);
    return x + y;
}
```

Als de functieoproepen f en g er niet zijn, dan moeten x en y niet op de stack. Bij de functie f hangt het af of dat f de parameter aanpast. Bij de functie g moet x zeker in het geheugen zitten en zal dus niet op de stack komen.

```
int f(int x, int y){
    p = &x;
}
```

6.2 Frames in de Tiger compiler

6.2.1 Frame Interface

Er is een abstracte representatie nodig van een frame want deze hangt af van de architectuur. Deze komt in `frame.h`.

- `F_frame`: datastructuur die een frame voorstelt.
- `F_access`: datastructuur die specificeert hoe lokale variabelen moeten geaccesseerd worden (register of geheugen).
- `F_accessList`: Lijst van `F_access` structuren.
- `newFrame(Temp_label name, U_boolList formals)`: `formals` bevat booleans die voor elke parameter aangeeft of hij deze escapet moet worden of niet.
- `allocLocal(F_frame f, bool escape)`: maakt plaats voor nieuwe veranderlijke in frame f , en eventueel is deze escapet.

Voorbeeld:

[illegible]

	Pentium	MIPS	Sparc
Formals	1 InFrame(8)	InFrame(0)	InFrame(68)
	2 InFrame(12)	InReg(t_{157})	InReg(t_{157})
	3 InFrame(16)	InReg(t_{158})	InReg(t_{158})
View Shift	$M[\text{sp} + 0] \leftarrow fp$	$\text{sp} \leftarrow \text{sp} - K$	<code>save %sp, -K, %sp</code>
	$fp \leftarrow \text{sp}$	$M[\text{sp} + K + 0] \leftarrow r2$	$M[fp + 68] \leftarrow i0$
	$\text{sp} \leftarrow \text{sp} - K$	$t_{157} \leftarrow r4$	$t_{157} \leftarrow i1$
		$t_{158} \leftarrow r5$	$t_{158} \leftarrow i2$

Figuur 6.2: Formele parameters voor $g(x_1, x_2, x_3)$ waarbij x_1 escapes.

6.2.2 Creatie en initialisatie van frames

Bij Pentium moet alles op de stack. In MIPS wordt standaard de eerste 3 argumenten in registers gestoken, maar x_1 escapet dus wordt toch in de stack gestoken.

6.2.3 Escapes berekenen

Een variable *escapet* uit een stack frame als:

- hij passed-by-reference wordt.
- of zijn adres genomen wordt.
- of hij geaccessed wordt vanuit een geneste functie.


Pass-by-reference of het nemen van een referentie is direct zichtbaar in de Abstract Syntax Tree. Om na te gaan of hij geaccessed wordt vanuit een geneste functie wordt de Abstract Syntax Tree recursief overlopen met een symbooltabel (omgeving), maar hier zijn alle veranderlijken gebonden aan booleans: escapes of niet. Deze stap wordt voor semantische analyse en na parsing gedaan. Dus tussen deze twee stappen worden de escapes berekend. Het kan ook efficiënter, maar zien we niet in deze cursus.

6.2.4 Temporaries en Labels

- Een **temporary** is een waarde die tijdelijk in een nog te bepalen register wordt bewaard.
- Een **label** is een nog onbekend adres waarde code of statisch gealloceerde data zal terecht komen. Bijvoorbeeld `string = "een string"` wordt statisch gealloceerd.
- Er is ook een aparte interface `temp.h`.

Hoofdstuk 7

Intermediate Representations



Figuur 7.1: Compilers voor vijf talen en vier architecturen: (links) geen IR, (rechts) met IR.

Een goede IR moet:

- makkelijk te produceren zijn door de compiler frontend
- makkelijk zijn om er echte assembler van te genereren
- duidelijke, eenvoudige betekenis hebben

Een IR-tree is een eenvoudige abstractie van machine-instructies. Het lijkt heel goed op een Abstract Syntax Tree maar is taal-onafhankelijk en werkt met temporaries in plaats van variabelen.

Typen van expressies (T_{exp}):

- $CONST(i)$: integer constante i
- $NAME(n)$: assembly label n
- $TEMP(t)$: virtueel register t
- $BINOP(o, e_1, e_2)$: $e_1 o e_2$ met $o = +, -, *, / , \dots$. Hier wordt e_1 altijd eerst geëvalueerd.
- $MEM(e)$: De inhoud van w bytes op e schrijven of lezen.

- **CALL**(f, l_1, \dots, l_n): roep f op met argumenten l_i . De volgorde van de argumenten is van belang.
- **ESEQ**(s, e): evalueer s voor neveneffecten, dan e als resultaat.

Typen van statements:

- **MOVE**(TEMP t, e): evalueer e en wijs toe aan temp t .
- **MOVE**(MEM(e_1), e_2): evalueer e_1 tot adres a , evalueer e_2 en schrijf het in de w bytes vanaf a .
- **EXP**(e): evalueer e en negeer het resultaat.
- **JUMP**(e, labs): evalueer e tot een adres en spring er naar.
- **CJUMP**($e \dots$):
- **SEQ**(s_1, s_2): sequentie van statements

Er is geen 1-op-1 mapping van **A_EXP** naar **T_EXP**.

Q: Waarom staan er NULL pointers?

A: We weten nog niet naar waar we moeten springen. Er moeten labels inkomen, maar we kennen ze nog niet. Voorlopig dienen die dus als placeholders.

patchlist bevat de labels (in gelinkte lijst vorm) in geval van true en geval van false. De constructor bevat het hele pad in de IR tree naar het lege veld vanaf de root van het statement (s_1 in voorbeeld). Als de waarde 0 of 1 in **flag** moet komen kan de expressie geconverteerd worden naar een andere expressies. Program 7.3: steek 1 in temporary, als we false uitkomen wordt 0 in temporary gestoken. De doPatch functie kent een label toe aan een bepaald veld in de boom.

7.0.1 Omzetting enkelvoudige veranderlijken

+ symbool is dereference operator

l-values:

- kan links in een toewijzing voorkomen
- verwijst naar een locatie

r-values:

- kan enkel rechts in een toewijzing voorkomen
- verwijst impliciet naar een waarde

scalar:

- Waarde die slechts één geheugenwoord bevat.

Hoofdstuk 8

Basisblokken en traces

Probleem met IR tree: soms is volgorde van uitvoering in de tree niet bepaald. We zouden de knopen van de IR tree kunnen herordenen.

Ander probleem: in een functiecall kan een parameter ook een functiecall zijn. De binneste functiecall moet eerst uitgevoerd worden.

Het is nog niet gemakkelijk om machinecode te genereren.

8.1 Canonical trees

8.2 Linearizeren

Door associativiteit kan de tree omgevormd worden tot een lijst van statements. Onder elke statement kunnen complexe expressies hangen in de vorm van subtrees.

8.3 Basic blocks

Algemene definitie: een sequentie van statements. Als één statement uitgevoerd wordt, moeten alle andere statements van dit block uitgevoerd worden. Een basic block start met een **LABEL** statement en eindigt met een **JUMP** of **CJUMP** statement.

8.3.1 Traces aanmaken

Een trace is een sequentie van basisblokken die mogelijk na elkaar uitgevoerd kunnen worden. De trace kan nog opgekuist worden zodat het false pad van een basisblok gevolgd wordt door zijn opvolger binnen een trace.

Hoofdstuk 9

Instructieselectie

De meeste architecturen hebben complexere instructies dan degene die in de IR tree gegeven zijn.

De optimale bedekking is NP-compleet. Het Maximal Munch algoritme zoekt de optimale tiling, maar geen minimum.

RISC	CISC
32 registers	weining registers
Register-register architectuur	Memory-memory architectuur
3-adresinstructies: $R1 \rightarrow R2$ op $R3$	2-adresinstructies: $R1 \rightarrow R1$ op $R2$
1 adresseermode	veel adresseermodes
Vaste instructielengte	variabele instructielengte

Variabele instructielengte is geen probleem:

slide 20: onbelangrijk

Hoofdstuk 10

Liveness analyse

10.1 Control Flow Graphs

Een niet-lineaire voorstelling van de assemblycode die uitgevoerd wordt. Elke knoop in de graaf stelt een instructie voor.

Q: Hoeveel registers zijn er nodig om de temporaries a , b en c bij te houden?

A: Eerst afvragen waar in het programma de waarde van a een rol kan spelen. De set van punten na een bepaalde instructie wordt de **out set** genoemd.

Het is minder interessant wat de sets exact zijn, maar wel de plaatsen waar meerdere veranderlijken voorkomen. De liveness range is het bereik dat een bepaalde veranderlijke levend is in het programma.

Hoe liveness berekenen? Vergelijking 10.3 oplossen.

- Iteratief algoritme
- Itereer over alle blokken in de graaf in omgekeerde volgorde (van onder naar boven).
 - Maak kopie van de in en out sets
 - Bereken de nieuwe in set
 - Bereken de nieuwe out set
- Blijf dit doen zolang er een set gewijzigd wordt.

Complexiteit:

- Stel programmagrootte: N statements.
- Elk statement kan maar 1 veranderlijke updaten, dus maximum N veranderlijken.
- De set operatie is $O(N)$.
- De for loop is dan $O(N^2)$.
- In elke iteratie minsten 1 element toevoegen door een monotone update, dus max $2N^2$ iteraties van de repeat loop.
- Complexiteit: $O(N^4)$.

- In realiteit is het bijna lineair.

Voorstellingen van sets:

- Eenvoudigste voorstelling van een set: bitvectoren. Bijvoorbeeld 64 bits, als bit 3 op 1 staat, zit 3de temporary in de s
- Als er te veel temporaries zijn kan gelinkte lijst gebruikt worden

et

Least Fixed Point & Conservativiteit

Q: Kan Y een probleem geven? Kan Z een probleem geven?

A: De Y analyse zal nog steeds een correct programma opleveren, maar het is niet optimaal. De Z analyse zal registers overschrijven.

Een analyse is conservatief als het gedrag van het programma niet gewijzigd wordt.

10.2 Statische approximatie

Q: Waarom is dit slechts een benadering?

A: Onbeslisbare problemen kunnen niet opgelost worden.

10.3 Interference Graph

We zijn enkel geïnteresseerd welke sets meerdere veranderlijken bevat. De interference graph verbindt knopen die samen kunnen voorkomen.

Hoofdstuk 11

Registerallocatie

Graph coloring om registers te alloceren in een interference graph.

Met sommige knopen geen rekening houden (bv h , want er zullen toch twee kleuren overblijven want heeft maar 2 buren).

1. Vereenvoudig de graaf door continue knopen met een graad $< k$ weg te laten. Steek ze op een stack.
2. Pop and color: selecteer een kleur en voeg knoop terug toe met die kleur aan de graaf.

11.1 Register Coalescing

Knopen die kopieën bevatten proberen samen te voegen als die het kleuren hoogstwaarschijnlijk niet bemoeilijken.

Twee heuristieken die het kleuren zeker niet moeilijker maken:

- heuristiek van Briggs: als samengevoegde knoop minder dan K buren van significante graad heeft
- heuristiek van George: Elke buur t van a is ofwel een buur van b ofwel niet van significante graad.

Hoofdstuk 12

Data Flow Analysis

Compilers maken programma's kleiner, sneller. Zelfs perfecte $C++$ code kan nog steeds verbeterd worden. Een ontwerper van een programmeertaal gaat ervan uit dat een compiler veel *under the hood* functies heeft.

12.1 Analyse en transformaties

- Verzamel informatie
- Controleer de eigenschappen (precondities)
- Voer de transformatie uit

Interproceduraal = van meerdere procedures informatie verzamelen zodat een functie eigenschappen kan bevatten van andere functies.

Lokaal = slechts één blok wordt bekeken in een functie

Globaal = alle blokken in een functie wordt bekeken

```
a = 1
b = a
a = 2
c = a
```

Welke waarde zit in c ?

Flow insensitief = slechts één eigenschap bijhouden per variabele.

```
a = ?
b = ?
```

Flow sensitief = per blok in het programma eigenschappen bijhouden

```
a1 = 1
b = a1
a2 = 2
c = a2
```

als een blok van meerdere paden kan bereikt worden, kan een variabele meerdere waarden aannemen.
 Pad insensitief = geen rekening houden met het pad, zodat we niet weten welke waarde een variabele heeft

Pad sensitief = Wel rekening houden met de verschillende paden

Voorbeeld slide 4

- Javacode
- In veld f van type A kan ofwel object van type B of C zitten.
- De `toString()` methode kan ofwel die van B of van C oproepen. Maar het is duidelijk dat het van type B is, dus er is iets fout gelopen in de analyse.
- Voeg virtuele klassen $A1$ en $A2$ toe die beiden een attribuut f hebben die respectievelijk een object van type B en C kunnen hebben.
- Het object o zal nu zeker weten dat de `toString()` van object B opgeroepen moet worden.

Niet altijd nuttig om zo sensitief mogelijk te gaan = te veel geheugen nodig.

12.2 Reaching definitions

Een niet-ambigue definitie d van t is

$$d : t \leftarrow M[a] \quad \text{of} \quad t \leftarrow a + b$$

Een ambigue definitie: call die al dan niet de waarde van t wijzigt.

Een statement d is reaching definition van statement u als er een pad van d naar u bestaat waarop geen niet-ambigue definitie van t voorkomt. Controleer in de controleverloopgraaf. Als de definitie van t niet aangepast wordt dan is d een reaching definition van u . Zie tabel 17.2: de gen- en killset zijn sets van statements, bij liveliness is het set van temporaries. In andere woorden: hoe lang is een definitie van een veranderlijke geldig (vergelijkbaar met liveliness analyse, maar de vergelijking is met de unie van predecessors).

```
d_2: t \left ...
d_1: t \left ...
d: t \left ...
...
...
u: ...
```

Q: Waarom is reaching definitions nuttig?

A: Als je op een bepaald punt ziet dat er geen reaching definition is, dan zit je met een uninitialized variabele.

12.3 Available expressions

Een expressie $aopb$ is available bij statement u als $aopb$ op elk een pad naar u berekend wordt, en tussen die berekening en u worden a en b niet meer gewijzigd. De gen- en killset zijn nu verzamelingen van expressies.

```

x \leftarrow t \times u
t \leftarrow ...
x \leftarrow t \times u

```

De killset zijn alle expressies waar t in zit.

Q: Waarom is het nuttig?

A: Om te controleren of dat expressies opnieuw moeten berekend worden of niet.

Terug voorwaartste vergelijking: belangrijk verschil met vorige vergelijkingen: het gaat over de doorsnede van de predecessors. Hoe initialiseren? De maximale set: alle expressies in het programma.

12.4 Optimalisaties

- Common-subexpression elimination
 - In plaats van nieuwe berekeningen uit te voeren, gebruik het resultaat van vorige berekeningen
- Constant propagation
 - Stel dat je aan $t \leftarrow 3$
 - Dan $a = txb$
 - Als je weet dat er slechts één toekenning (via reaching definitions) is van t , dan kan t vervangen worden door de constante 3.
 - Als dit voor b ook zou zijn, dan wordt (voor $b = 2$) $a = 6$.
 - Via reaching definitions voor a kan zo verder geoptimaliseerd worden.
- Copy propagation
 - ! Waarom niet gewoon coalescing tijdens register allocation?
 - ◊ Omdat sommige optimalisatiemogelijkheden verdwijnen
- Dead code elimination
 - Ergens een definitie die nooit gebruikt wordt
 - Statement schrappen.

Deze optimalisaties worden iteratief uitgevoerd: het toepassen van een optimalisatie laat nieuwe optimalisaties toe.

12.5 Snellere analyses

1. Bitvectors
2. Slechts voor elk basic blok toepassen.
3. Volgorde van toepassen aanpassen (zie algoritme onderaan slide 15)
4. Er wordt enkel de out set bijhouden, de inset wordt telkens opnieuw berekend omdat die vaak kleiner zijn, zodat er minder geheugen nodig is om al de sets bij te houden.
5. chains

- use def = bijhouden van alle reaching definitions van een temporary
- def use = omgekeerd

6. Work-list algoritme houdt bij waar er nog berekeningen nodig kunnen zijn. (algoritme 17.6)

12.6 Incrementele analyses

Elke transformatie heeft invloed op resultaten van de analyse. Moeten we dan de hele analyse opnieuw doen? Als z dood is, moet van onder naar boven elke keer het statement verwijderd worden bij elke iteratie.

12.7 Value Numbering

Elke expressie een nummer geven en hergebruiken van die expressies.

12.8 Incremente livenessanalyse

Veel te moeilijk om te implementeren, wordt bijna nooit gebruikt.

12.9 Alias Analysis

Niet in detail te kennen

Kunnen p en q naar hetzelfde object wijzen (may-alias informatie)? Wijst p en q naar hetzelfde object (must-alias informatie)?

Een zeer moeilijke analyse en hebben maar een beperkte precisie (in bv C en $C++$)

Herordenen van geheugenoperaties: waarom is dit van zo een groot belang? voor parallelisatie.

Hoofdstuk 13

Loop Optimizations

Formele definitie van een lus: verzameling knoepn S met daarin een header h , vanuit elke knoop in de lus kan je naar h , van h kan je naar elke knoop in S , externe pijlen komen enkel toe in h .

De knopen in een lus vormen een *strongly connected component*: vanuit één knoop in de lus kan elke andere knoop in de lus bereikt worden. De back edge is de verbinding die de een knoop naar de header verbindt

Reduceerbaarheid = niet te kennen. Enkel weten dat lussen volledig overlappen of helemaal niet. Ze kunnen niet deels overlappen.

13.1 Dominators

- Veronderstel 1 startknoop s_0 van de CFG .
- Knoop d domineert knoop n als elk pad van s_0 naar n door d gaat.
- Eenvoudig berekenen met data flow analyse. Hoe initialiseren? maximale sets.
- In plaats van data flow analyse kan ook de dominator tree opgesteld worden. De dominator set van een knoop is dan de opeenvolging van ouderknoepen.

Eigenschappen van een dominator:

- Transitief: $a \text{ dom } b$ en $b \text{ dom } c \rightarrow a \text{ dom } c$.
- Als $e \text{ dom } n$ en $d \text{ dom } n$, dan $e \text{ dom } d$ of $d \text{ dom } e$.
- Elke knoop n heeft een unieke immediate dominator $\text{idom}(n)$

13.1.1 Header loops

- Een header h kan header zijn van meerdere lussen.
- Loops kunnen genest zijn.
- Een loop-nest tree geeft aan welke knopen op welk loopniveau ze zitten.

13.1.2 Loop preheader

- Algemene code die voor een lus moet uitgevoerd worden.
- Handig als er meerdere paden naar de header van de lus zijn.

13.2 Loop Invariant Computations

- Berekeningen die altijd dezelfde waarde hebben kunnen buiten de lus geplaatst worden. (! niet altijd, soms is herberekenen beter dan de registers te gebruiken)
- Een definitie $d : t \leftarrow a_1 op a_2$ is loop-invariant als voor elke a_i :
 - a_i een constante is;
 - alle definities van a_i die d bereiken bevinden zich buiten de lus;
 - of de enige definitie van a_i , die d bereikt, loop-invariant is.

Voorbeelden: mogen we $t \leftarrow a + b$ voor de loop zetten?

Oppassen met side-effects: exceptions, pointer dereferencing

13.2.1 Conversie lussen voor LCIM

13.3 Inductieveranderlijken

13.4 Loop unrolling

Deel II

Oefeningensessies

Hoofdstuk 14

Oefeningensessie 1

14.1 Oefening 3.6 p85

Gegeven de volgende grammatica:

$$S \mapsto uBDz$$

$$B \mapsto Bv$$

$$B \mapsto w$$

$$D \mapsto EF$$

$$E \mapsto y$$

$$E \mapsto$$

$$F \mapsto x$$

$$F \mapsto$$

1. Bereken nullable, FIRST en FOLLOW.

	nullable	FIRST	FOLLOW
S	nee	{ u }	/
B	nee	{ w }	{ x, y, v, z }
D	ja	{ x, y }	{ z }
E	ja	{ y }	{ x, z }
F	ja	{ x }	{ z }

2. Construeer de $LL(1)$ parsingtabel.

	u	z	v	w	y	x
S	$S \mapsto uBDz$					
B				$B \mapsto w, B \mapsto Bv$		
D		$D \mapsto EF$			$D \mapsto EF$	$D \mapsto EF$
E		$E \mapsto$			$E \mapsto y$	$E \mapsto$
F		$F \mapsto$				$F \mapsto x$

3. Toon aan dat dit geen $LL(1)$ parser is.

Als we B aan het parsen zijn, en het eerstvolgende token is een w dan weten we niet welke productieregel toegepast moet worden.

4. **Wijzig de grammatica zo weinig mogelijk om een $LL(1)$ grammatica te hebben dat dezelfde taal aanvaardt.**

Door de linkse recursiviteit van de productieregel $B \mapsto Bv$, kan je volgende veranderingen invoeren:

$$B \mapsto wB'$$

$$B' \mapsto vB'$$

$$B' \mapsto$$

14.2 Voorbeeldexamenvraag

Gegeven de reguliere expressie $S = ab + c$.

1. **Schrijf een (ambigue) grammatica voor S met tokens a , b en c .**

$$S' \mapsto S\&$$

$$S \mapsto aBc$$

$$B \mapsto bB$$

$$B \mapsto b$$

2. **Geef de $LR(0)$ statentabel en $LR(0)$ parsingtabel.**

Altijd de closure nemen van productieregel van niet-terminal waar het puntje voor staat. dus alle productieregels opnemen in toestand van die niet-terminal. Uiteindelijk moet elk puntje op het einde staan

	a	b	c	\$	S	B
1	s3				g2 ¹	
2						
3		s5 ²				g4
4			s7			
5	r3 ³	s5,r3	r3	r3		g6
6	r2	r2	r2	r2		
7 r1	r1	r1	r1			

3. **Zijn er conflicten? Waarom wel of niet?**

Er is een shift-reduce conflict voor toestand 5 en token b . Dit komt omdat de gekozen grammatica ambigue is.

4. **Construeer een niet-ambigue LL parsingtabel die deze expressie herkent. Indien nodig, maak de grammatica niet-ambigue.**

Grammatica herschrijven:

$$S \mapsto aBc$$

$$B \mapsto bB'$$

$$B' \mapsto$$

$$B' \mapsto B$$

nullable, FIRST en FOLLOW bepalen:

$LL(1)$ parsing table opstellen:

	nullable	FIRST	FOLLOW
S	nee	{ a }	/
B	nee	{ b }	{ c }
B'	ja	{ b }	{ c }

	a	b	c
S	$S \mapsto aBc$		
B		$B \mapsto bB'$	
B'		$B' \mapsto B$	$B' \mapsto$

14.3 Oefening 3.13 p86

Toon aan dat de volgende grammatica $LALR(1)$ is maar niet SLR :

- 0 : $S \mapsto X\&$
- 1 : $X \mapsto Ma$
- 2 : $X \mapsto bMc$
- 3 : $X \mapsto dc$
- 4 : $X \mapsto bda$
- 5 : $M \mapsto d$

Hoofdstuk 15

Oefeningensessie 2

15.1 Oefening 6.3 p147

Geef voor elk van de veranderlijken a, b, c, d, e in het volgende programma aan of ze in het geheugen of in een register moeten bewaard worden, en waarom.

```
int f(int a, int b){
    int c[3], d, e;
    d = a + 1;
    e = g(c, &b);
    return e + c[1] + b;
}
```

variabele	locatie	reden
a	register	de variabele wordt enkel lokaal in de functie gebruikt
b	geheugen	het adres van b wordt opgevraagd en escapet dus de stack
c	geheugen	een array zit altijd in het geheugen
d	register	de variabele wordt enkel lokaal in de functie gebruikt
e	register	de variabele wordt enkel lokaal in de functie gebruikt

15.2 Oefening 8.6 p190

Deel het volgende programma op in basisblokken.


```
1      m := 0
2      v := 0
3      if v >= n:          goto 15
4      r := v
5      s := 0
6      if r < n:          goto 9
7      v := v + 1
8      goto 3
9      x := M[r]
10     s := s + x
11     if s <= m:          goto 13
12     m := s
```



```

13      r := r + 1
14      goto 6
15      return m

```



15.3 Oefening 9.1 p217

?