

Systeemontwerp

Bert De Saffel

Master in de Industriële Wetenschappen: Informatica Academiejaar 2018–2019

Gecompileerd op 18 januari 2019

Inhoudsopgave

1	Inleiding	3
1.1	Softwarearchitectuur	3
1.1.1	Systeemrequirements	3
1.1.2	4+1 view model	3
1.2	Reactive manifesto	4
I	Microservices	5
2	Architectuurstijlen	6
2.1	Gelaagde stijl	6
2.2	Hexagonale stijl	6
2.3	Monolithische stijl	6
2.4	Microservices	7
3	Decompositie van een applicatie	8
4	Interactiestijlen tussen services	9
4.1	Synchrone communicatie	9
4.1.1	Voorbeelden	9
4.1.2	Foutbestendigheid	10
4.2	Asynchrone communicatie	10
4.2.1	Foutbestendigheid	11
4.3	Vermijden van synchrone communicatie	11
5	Saga	13
6	Domeinlogica van een microservice	15
7	Queries in een microservice architectuur	16

II	Container deployment and orchestration	17
8	Productieomgeving	18
9	Containers	20
9.1	Docker Architecture	21
10	Container orchestration	23
10.1	Kubernetes	23
10.2	Dimensies van cloud computing	25
10.2.1	Essentiële eigenschappen	25
10.2.2	Cloud service models	26
10.2.3	Cloud deployment models	26
10.3	Elastische schaling	26
III	Distributed Data Storage & Processing	28
11	De uitdagingen van moderne data	29
12	Datamodellen	30
12.1	Het relationeel model	30
12.2	Het document model	30
12.3	Het graaf model	30
12.4	Het kolomfamilie model	31
13	Opslaan en ophalen van informatie	32
14	Gedistribueerde informatie	34
14.1	Replicatie	34
14.1.1	Leader-Follower model	35
14.1.2	Leaderless model	35
15	Partitionering	37
15.1	Herbalancering	37
15.2	Request Routing	37
16	Consistentie en Consensus	39

Hoofdstuk 1

Inleiding

- Systeemontwerp = het ontwerpen van een infrastructuur waarbij verschillende componenten met elkaar kunnen interageren.
- Typische high level architectuurblokken:
 - transactiebehandeling: requests behandelen van gebruikers.
 - business intelligence: geproduceerde data analyseren.

1.1 Softwarearchitectuur

1.1.1 Systeemrequirements

- functionele requirements: specificatie wat een systeem moet **doen**.
- niet-functionele requirements: specificatie wat een systeem moet **zijn** (kwaliteitseisen).

1.1.2 4+1 view model

- Logical view:
 - Bevat de software-elementen die gemaakt worden door ontwikkelaars (**domain class diagram** en **entity-relationship diagram**).
- Implementation view:
 - Bevat de output van het build systeem, zoals de verschillende modules (bv JARs) en componenten (executables, WARs).
 - Beschrijft de onderliggende relaties tussen alle modules en componenten (import, use, merge, ...)
- Process view:
 - Bevat de beschrijving van de werking van verschillende processen (een proces kan een hele module zijn) (**activity diagram**).
 - Een proces kan beheerd worden: starten, pauzeren, configureren, stoppen.
 - Heeft als doel om deadlocks en netwerkvertragingen te voorkomen en consistentie te bereiken.

- Deployment view:
 - Beschrijft op welke toestellen de processen moeten gedeployed worden, hoeveel toestellen er gebruikt worden.
 - Verschillende deploymentconfiguraties mogelijk per klant of geografisch gebied, maar ook of dat het een productie of ontwikkelomgeving is.
- +1 Use Cases/Scenarios:
 - Een use case beschrijft, binnen een view, hoe dat de componenten binnen die view met elkaar interageren voor een bepaalde situatie.
 - Is eigenlijk redundant omdat andere 4 views deze informatie ook al bevatten, maar use cases zijn toch nuttig:
 - ✓ Het valideert het ontwerp.
 - ✓ Het kan nieuwe systeemelementen ontdekken.

1.2 Reactive manifesto

4 kenmerken:

- Message Driven: asynchrone communicatie tussen componenten. Maakt gebruik van een wachtrij om de berichten te beheren. Dit heeft drie voordelen:
 - ✓ Zwakke koppeling: de verschillende componenten moeten enkel een protocol afspreken voor het bericht.
 - ✓ Loskoppelen van de tijd: Zender en ontvanger moeten niet wachten op elkaar.
 - ✓ Loskoppelen van locatie: De zender en ontvanger moeten niet in hetzelfde proces beschikbaar zijn, enkel de locator (**analogie met gsm-nummer, ik kan eender waar naar iemand bellen, onafhankelijk van zijn locatie**) moet bekend zijn.
- Responsief:
 - Lazy loading
 - Toon progressbar
 - Een trage service mag andere services niet beïnvloeden.
- Elastisch:
 - Predictieve en reactieve schaling
 - Resources moeten voor elk individueel component instelbaar zijn
 - Systeem moet responsief blijven
- Foutbestendig:
 - Systeem moet zichzelf kunnen herstellen
 - Fouten moeten snel opgespoord kunnen worden via monitoring
 - Voorzie fallback services

Deel I

Microservices

Hoofdstuk 2

Architectuurstijlen

2.1 Gelaagde stijl

- Kan toegepast worden op elk view model.
- 3 lagen in het **logische view**: persistentie, presentatie en domeinlogica.
- ✓ Robust systeem.
- ✓ Eenvoudig om te ontwikkelen (veel frameworks ondersteunen dit: Java EE, .NET, ...).
- ✓ De verschillende lagen kunnen gemockt worden om eenvoudig testen uit te voeren.
- ! Slechts één presentatielaag, maar er kunnen verschillende clients zijn (desktop, mobile, tablet, ...).
- ! Slechts één persistentielaag, maar er kunnen verschillende databasetechnologiën nodig zijn.
- ! De domeinlogicalaag definieert repositories, maar de persistentielaag implementeert deze. De dependency is dus omgekeerd.

2.2 Hexagonale stijl

- Maakt gebruik van adapters. Deze adapters zijn interfaces en kunnen opgesplitst worden:
 - **Inbound adapter**: Dit is API dat de domeinlogica openstelt, zodat deze kan aangeroepen worden door externen. Elke client kan nu onafhankelijk van elkaar ontwikkeld worden. Ze moeten enkel maar de API aanroepen.
 - **Outbound adapter**: Dit is de API die de domeinlogica kan gebruiken (repository interface, payment interface).
- ✓ presentatie-, persistentie- en domeinlogicalaag zijn losgekoppeld.

2.3 Monolithische stijl

- Een monolithische applicatie kan enerzijds de gelaagde en anderzijds de hexagonale architectuur bevatten.

- ✓ Makkelijk te ontwikkelen met een IDE.
- ✓ Eenvoudig om wijzigingen door te voeren: edit → build → deploy.
- ✓ Eenvoudig te testen.
- ✓ Eenvoudig om te deployen.
- ! Voor grote codebases wordt het moeilijk om elk detail van de codebase te kennen.
- ! Een kleine wijziging resulteert in het rebuilden van de hele applicatie.
- ! Een bug kan het hele systeem onbereikbaar maken.
- ! Replicatie is haast onmogelijk.
- !

2.4 Microservices

- Decomposeerd een applicatie in kleine, zwak gekoppelde services, die individueel kunnen ge-deployed worden.
- Services communiceren met elkaar via APIs. Deze API biedt toegang tot functionaliteit en kent drie soorten operaties:
 - **Command:** Een operatie dat een wijziging zal doorvoeren.
 - **Query:** Een operatie dat enkel informatie zal ophalen.
 - **Event:** Een operatie dat andere services zal inlichten indien een bepaalde gebeurtenis optreedt.
- Wordt geïmplementeerd in de implementatie view. Elke service heeft zijn eigen logische view.
- Wat is een service?
 - Bevat een bepaalde nuttige functionaliteit.
 - Deze functionaliteit wordt via een API beschikbaar gesteld.
- Wat is een micro-service?
 - Voert een kleine operatie, en enkel die operatie, uit.
 - Kan door een klein ontwikkelteam beheerd worden.
 - ! Betekend niet dat de service zo klein mogelijk moet zijn.
- ✓ Elke service kan onafhankelijk van elkaar ontwikkeld worden.
- ✓ Elke service heeft zijn eigen databank.
- ✓ De interne staat van elke service is niet bekend voor buitenstaanders.
- ! De juiste services vinden is moeilijk.
- ! Foute decompositie leidt tot een gedistribueerd monolithisch systeem.
- ! Gedistribueerde systemen zijn complex (bv. geen IDE die dit ondersteund).
- ! Communicatie tussen services over een netwerk is traag.
- ! Vele verschillende services kunnen op hetzelfde moment aan het draaien zijn.

Hoofdstuk 3

Decompositie van een applicatie

Het proces om een applicatie in te delen in verschillende microservices wordt **decompositie** genoemd. Dit **iteratief** proces is belangrijk aangezien een foutieve methode leidt tot ongewenste resultaten. Een dergelijk proces kan opgedeeld worden in drie stappen.

1. **Identificatie van de systeemoperaties.** Dit omvat het vertalen van de noden van één of meerdere gebruikers naar user stories en use-cases. Vaak wordt er hier overlegd met enkele domeinexperts. Het is belangrijk om te achterhalen wat belangrijke systeemoperaties zijn. Welke informatie moet er met een *create*, *update* of *delete* gewijzigd worden? Welke informatie moet met een *query* opgehaald worden? In deze fase worden er nog geen technische vaststellingen gedaan. De focus ligt namelijk op het vaststellen van de pre- en postcondities van de verschillende systeemoperaties.
2. **Identificatie van de services.** Services specificeren handelingen dat een bedrijf kan doen. Voorbeelden voor een online webshop zijn: *Sales*, *Marketing*, *Payment*, *Order Shipping* en *Order Tracking*. Deze services blijven lang stabiel en zullen haast nooit veranderen tenzij de business een shift van focus doet. In deze stap kunnen er vier obstakels voorkomen:
 - (a) **Godklassen:** Dit zijn klassen die te veel verantwoordelijkheid op zich dragen. De juiste oplossing is het opsplitsen van de klasse in verschillende klassen op basis van de bestaande services. Deze verschillende klassen kunnen in een microservice gestoken worden waarbij de definitie van de klasse sterk gedaald is (ze moet maar gelden binnen de microservice). Voorbeeld van een godklasse is een *Order* klasse voor pizza's. Denk aan de typische attributen: *status*, *requestedDeliveryTime*, *prepareByTime*, *deliveryTime*, *paymentinfo*, *deliveryAddress*, enz. Het opsplitsen van deze klassen kan bijvoorbeeld gebeuren door enkel informatie die relevant is voor de keuken, in een keukenservice te steken en informatie die enkel relevant is voor het bezorgen van een bepaalde order in een deliveryservice. Op die manier worden godklassen vermeden.
 - (b) **Netwerkvertraging:** Alle communicatie tussen services verloopt over een netwerk. Er moet zoveel mogelijk operaties over het netwerk vermeden worden. Een oplossing is om een aantal services te combineren.
 - (c) **Synchrone operaties:** Operaties die synchroon verlopen moeten zoveel mogelijk vermeden worden om de beschikbaarheid van de services allessinds te kunnen garanderen.
 - (d) **Applicatie-informatie is gescheiden:** Alle informatie die de applicatie genereert is verspreidt over elke microservice en soms zelfs gedupliceerd. Bij een microservice architectuur is er nooit dat de informatie consistent is.
3. **Identificatie van de service API's.** Deze laatste stap zal nagaan welke operaties van een microservice publiek moeten gesteld worden aan de buitenwereld via een API.

Hoofdstuk 4

Interactiestijlen tussen services

	one-to-one	one-to-many
synchroon	request/response	/
asynchroon	request/async response one way notifications	publish/subscribe publish/async response

- request/response: Een service stuurt een request en wacht op een response.
- request/async response: Een service stuurt een request, maar wacht niet noodzakelijk op een response.
- one way notifications: Een service stuurt een request en verwacht geen response.
- publish/subscribe: Een service publiceert een bericht en kan opgevangen worden door 0 of meerdere geïnteresseerden.
- publish/async responses: Een service publiceert een bericht en zal eventueel antwoorden opvangen van 0 of meerdere geïnteresseerden.

4.1 Synchrone communicatie

4.1.1 Voorbeelden

- REST
 - Definieert een API met resources en wordt vaak gebruikt in combinatie met HTTP.
 - Vier levels:
 - 0 : Enkel HTTP POST mogelijk. Elke actie krijgt dan ook een ander endpoint toegewezen.
 - 1 : Maakt gebruik van resources zodat elk individuele resource een URI krijgt. Nog steeds enkel HTTP POST mogelijk.
 - 2 : GET, POST, PUT mogelijk. Een zelfde resource kan nu meerdere operaties ondersteunen.
 - 3 : HATEOAS mogelijk: een GET request bevat, behalve het object, ook URLs die mogelijke acties op het object toelaten.
 - ✓ HTTP wordt niet geblokkeerd door een firewall.

- ✓ Implementeerd request/response interactie.
- ! clients moeten de locatie (URL) kennen.
- ! Meerdere resources in één request opvragen is moeilijk.
- ! Soms is het moeilijk om de HTTP werkwoorden te mappen op een operatie.
- gRPC
 - Google Remote Procedure Call.
 - API wordt gedefinieerd op basis van een Interface Definition File. Dit bestand bevat IDL (Interface Description Language) code.
 - Deze code wordt gecompileerd afhankelijk van de gekozen client.
 - ! Het valt niet op dat de communicatie nu over het netwerk gebeurt.

4.1.2 Foutbestendigheid

Communicatie tussen twee services moet foutbestendig zijn. Problemen zoals trage netwerken, overbelaste microservices, enz... moeten oplosbaar zijn. Er zijn drie methoden die geschikt zijn om technische problemen te voorkomen en op te lossen.

- **Netwerk-timeouts:** Zet een limiet op het aantal seconden dat een microservice wacht op een antwoord van een andere microservice.
- **Bulkheads:** Zet een limiet op het aantal requests dat een client kan versturen naar een service. Dit kan bijvoorbeeld geïmplementeerd worden door in een service die n andere services aanspreekt, n verschillende threadpools bij te houden. Als één van de n services een fout ondergaat, zal enkel de threadpool van die service volraken, terwijl de andere services nog steeds requests kunnen ontvangen.
- **Circuit breaker pattern:** Monitor het aantal succesvolle en gefaalde operaties van een service. Wanneer de verhouding van gefaalde en succesvolle operaties een bepaalde limiet overtreedt, dan wordt de circuit breaker (die de operaties monitored), geactiveerd en zal geen enkele request nog lukken.

Wanneer deze problemen zich voordoen, is het nuttig om een aantal fallback strategieën te hebben. Meestal is dit een fout of een gecached antwoord (indien van toepassing) terugsturen.

4.2 Asynchrone communicatie

- Maakt gebruik van messaging.
 - Point-to-point.
 - Publish-subscribe.
- ✓ Ondersteund alle interactiestijlen.
- Per service meerdere kanalen zoals het command kanaal, eventkanaal en reply-kanaal.
- Nooit zelf implementeren, maak gebruik van een message broker zoals ActiveMQ, Apache Kafka, RabbitMQ, ...
 - ✓ Verzenders moet enkel communicatie voorzien met de message broker, die dan de rest afhandelt.

- ✓ Buffert berichten indien de ontvanger trager is dan de verzender.
- Een message broker selecteren hangt af van volgende factoren:
 - ◇ **Berichtvolgorde:** Respecteert de broker de volgorde van de berichten?
 - ◇ **Ontvanggarantie:** Kan de broker garantie bieden dat een bericht werkelijk ontvangen wordt. Zoja, hoe (*best effort, at-least-once, exactly-once*)?
 - ◇ **Persistentie:** Worden berichten bewaard als de broker crasht?
 - ◇ **Duurzaamheid:** Krijgt een service die online komt de berichten die verstuurd zijn naar de service terwijl hij offline was?
 - ◇ **Schaalbaarheid:** Kan de broker een hoger aantal berichten per seconden aan?
 - ◇ **Vertraging:** Wat is de tijdsduur vooraleer een ontvanger zijn bericht krijgt?

4.2.1 Foutbestendigheid

Bij asynchrone communicatie kan het competing consumers probleem zich voordoen:

- **Meerdere instanties per service:** Het kan voorkomen dat er meerdere instanties van dezelfde service geïnteresseerd zijn in een bepaalde message stream. Er moet garantie zijn dan de berichten die toekomen in deze stream sequentieel afgewerkt worden.
- **Meerdere services per message stream:** Het kan ook zijn dat verschillende services geïnteresseerd zijn in dezelfde message stream. De berichten zouden dan gedupliceerd moeten worden, maar dat gaat niet met een standaard queue.

Deze problemen worden opgelost door een message broker zoals bijvoorbeeld Apache Kafka. Een Kafka cluster bestaat uit vijf componenten:

- **Topic:** Een categorie waarop berichten die bij de categorie horen geplaatst worden. Topics zijn gepartitioneerd.
- **Producers:** Processen die berichten plaatsen op een Kafka topic.
- **Consumers:** Processen die berichten lezen van een Kafka topic.
- **Broker:** Een process dat draait op een server die een bepaalde topic behandelt. Een server kan meerdere brokers hebben.
- **Zookeeper:** De coördinatie-interface tussen de kafka broker en de consumers.

Een ander probleem dat zich kan voordoen is het behandelen van dubbele berichten. De meeste message brokers voorzien geen exactly-once garantie, maar eerder een at-least-once garantie, om toch nog performant te zijn. Zulke brokers gaan een bericht als onzichtbaar markeren nadat het gelezen wordt door een consumer.

4.3 Vermijden van synchrone communicatie

Communicatie tussen verschillende microservices moet altijd asynchroon zijn. Synchrone communicatie heeft een negatieve impact op de bereikbaarheid van de applicatie. Hoe wordt synchrone communicatie vervangen door asynchrone communicatie?

- **Dupliceren van informatie:** Om er toch voor te zorgen dat een service s de meest up-to-date informatie behoudt, wordt eerst de originele informatie bijgehouden. Die informatie wordt naar de juiste services verzonden. Om een update van die informatie te ontvangen zal de service s zich abonneren op events die verstuurd worden bij het wijzigen van informatie. Dit is enkel nadelig bij grote hoeveelheden informatie, aangezien die allemaal gekopieerd moeten worden.
- **Synchroon eerst, asynchroon laatst:** Voer eerst de synchrone operaties uit tussen de client en de microservice. Nadat de client een antwoord heeft ontvangen kan de microservice asynchrone operaties tussen andere microservices uitvoeren. Het nadeel hier is dat de client moet pollen of dat de uiteindelijke operatie gelukt is.

Hoofdstuk 5

Saga

= garanderen dat een transactie ofwel volledig, ofwel niet uitgevoerd wordt.

- Traditioneel: 2-fasen-commit.
 - Eerst wordt elke databank naarwaar geschreven moet worden, op de hoogte gebracht van de informatie die ze moeten schrijven.
 - De eerste fase zal aan elke databank vragen of zij klaar zijn om weg te schrijven (prepare-fase).
 - De tweede fase zal effectief een commit uitvoeren op elke databank (commit-fase).
 - Van zodra één databank 'nee' antwoord, wordt het hele proces gestopt.
 - ! Synchron
 - ! Niet elke database implementeert het concept van transacties en locking.
- Saga
 - Een sequentie van lokale interacties tussen verschillende microservices. Voltooien van een stap in een microservice triggered de volgende stap in een andere microservice.
 - Elke systeemoperatie moet een saga hebben.
 - Bedoeld om informatie up to date te houden tussen verschillende microservices.

Elke microservice die deelneemt aan een bepaalde saga moet atomische transacties uitvoeren. De microservice moet zowel naar zijn database schrijven als de event uitsturen dat de volgende microservice mag beginnen. Om te voorkomen dat een saga faalt bij het crashen van een microservice, houdt elke microservice een transactielogboek bij. Dit logboek bevat alle wijzigingen die aan de databank doorgevoerd worden. De logs in dit logboek kunnen omgevormd worden tot berichten voor de message broker.

Het kan voorkomen dat een bepaalde regel binnen een saga niet voldaan is. Het moet mogelijk zijn om de saga ongedaan te maken. Om dit te implementeren zodat elke deelnemende microservice op de hoogte is, worden er compensatiemethoden geschreven. Read-only stappen en stappen die gevolgd worden door iets dat nooit zal falen in een saga moeten geen compensatiemethode bevatten.

Een saga moet gecoördineerd worden. Twee methoden:

- **Choreografie:** De keuzes worden gemaakt door de individuele microservices zelf. Microservices abonneren zich op bepaalde events en bepalen dan zelf wat er zal gebeuren indien dat event afgevuurd wordt.

- ! Domeinlogica wordt verspreidt over verschillende microservices.
- ! Cyclische dependencies tussen microservices.
- ! Sterke koppeling tussen microservices: elke microservice moet abonneren op elk kanaal dat nodig is.
- ✓ Eenvoudig te implementeren voor kleinere sagas.
- **Orchestratie:** Er is een centrale eenheid, de saga orchestrator, die commands verstuurt naar de microservices met verdere instructies. Nadat een microservice klaar is stuurt het een antwoord naar de orchestrator. De orchestrator bepaalt dan de volgende stap.
 - ! Te veel domeinlogica in de orchestrator.
 - ✓ Geen cyclische dependencies.
 - ✓ Zwakke koppeling tussen microservices.

Hoofdstuk 6

Domeinlogica van een microservice

Twee opties om de domeinlogica te representeren:

- **Transcription script:** Er wordt een procedure geschreven om elke command of query te behandelen. Deze procedures worden gegroepeerd in een controller klasse. Belangrijk bij dit patroon is dat er zowel klassen zijn met gedrag, als klassen die enkel een staat bijhouden. Deze methode is niet echt object-geëïntereerd programmeren, maar volstaat voor kleinere applicaties.
- **Domeinmodel:** Elke klasse krijgt een kleine verantwoordelijkheid. De controllerklasse in deze methode zal enkel delegeren naar andere klassen. Elke klasse heeft zowel gedrag als een staat. Een domeinmodel bestaat uit een aantal bouwstenen:
 - **Entiteiten:** Een unieke identiteit binnen een domeinmodel. Twee objecten met dezelfde waarden (bv naam) zijn toch twee verschillende objecten.
 - **Waardeobjecten:** Dit zijn objecten die geen identiteit hebben. Twee objecten met dezelfde waarden zijn wel gelijk.
 - **Domeinservices:** Dit zijn objecten die enkel gedrag voorstellen en hebben ook geen identiteit. Ze dienen om domeinlogica te orchestreren.
 - **Aggregaten:** Een groep van domeinobjecten die een consistent geheel vormen. Elke aggregaat heeft een wortel, en kan enkel via zijn ID aangesproken worden. Niet-root objecten mogen een referentie bevatten naar een root van een ander aggregaat. Een databanktransactie mag slechts één enkel aggregaat per keer updaten.
 - ◊ Een aggregaat moet domeinevents genereren wanneer hun staat gewijzigd wordt, maar mag niet verantwoordelijk zijn om deze events te publiceren op de message bus. De service die het aggregaat aanspreekt ontvangt het event, en zal dit event naar een Event Publisher sturen. Op die manier is er ook atomiciteit: zowel het opslaan als het aggregaat als het publiceren van het event moet gelukt zijn.
 - **Repositories:** Een klasse dat persistente gegevens ophaalt van de databank.

Hoofdstuk 7

Queries in een microservice architectuur

Twee patronen om queries op te bouwen die informatie nodig hebben van verschillende microservices:

- **API Composition:** De zogenaamde API Composer ontvangt een query en zal zelf de juiste microservices aanspreken. Dit kan op drie manieren geïmplementeerd worden:
 - **Client of the services:** *ToDo: wtf is dit?*
 - **API Gateway:** De API gateway is een aparte service die clients kunnen aanspreken en die de API composition logica bevat.
 - **Standalone service:** *ToDo: wtf is verschil met API gateway?*

Voordelen:

- ✓ Eenvoudig te implementeren.

Nadelen:

- ! Meer overhead omdat meerdere services aangesproken moeten worden.
- ! Risico op minder bereikbaarheid omdat de query nu afhangt van minstens 3 services.
- ! Kans op inconsistente data.
- ! Niet goed voor bijvoorbeeld locatie-gebaseerde queries.
- ! Elke service die informatie bevat over het object waarop een query wordt uitgevoerd, moet zich nu bezig houden met deze informatie via een API bloot te stellen.
- **CQRS:** Dit patroon splitst het domeinmodel op in een command gedeelte en een query gedeelte die beiden een aparte database hebben. Het query gedeelte ontvangt events van het command gedeelte om zo de eigen database up te daten. Voordelen:
 - ✓ Efficiënte manier om queries te implementeren die informatie opvragen van verschillende microservices.

Nadelen:

- ! Complexere architectuur.

Deel II

Container deployment and orchestration

Hoofdstuk 8

Productieomgeving

Een applicatie kan over een groot aantal services beschikken, die allemaal gebruik maken van verschillende technologieën. Een service kan eigenlijk beschouwd worden als een kleine applicatie, zodat er in plaats van één grote applicatie, meerdere kleinere applicaties in productie moeten draaien. Zo een productieomgeving moet vier functionaliteiten implementeren:

- **Service management interface.** Het in staat zijn om services te creëren, configureren en updaten, vaak via een shell of GUI.
- **Runtime service management.** De omgeving moet automatisch services kunnen herstarten indien deze gecrasht zijn. Ook als een fysieke server faalt, moet de omgeving een andere server aanspreken om de service op te draaien.
- **Monitoring.** Informatie over elke service instance zoals logbestanden en metrieke voor die bepaalde service (aantal bezoekers per seconde, success rate, ...) moeten beschikbaar zijn voor de ontwikkelaars, en moeten ook gewaarschuwd worden indien een service niet aan de vooropgestelde criteria voldoet.
- **Request routing.** De requests dat users versturen moeten naar de juiste service doorverwezen worden.

Volgende paragrafen bespreken hoe een aantal van deze zaken geïmplementeerd kunnen worden.

Een service heeft altijd een aantal configuratiegegevens (**environment variabelen** genoemd), die afhankelijk zijn van de omgeving waarin de service draait. Een service moet zo ontworpen zijn dat deze slechts éénmaal gecompileerd moet worden door de deployment pipeline, zodat deze meerdere malen in productie gezet kan worden. Het externaliseren van de configuratiegegevens betekent dat de configuratie van een service tijdens runtime bepaalt wordt. Hier zijn er twee modellen mogelijk:

- **Push model.** Bij dit model zal de service bij het opstarten configuratiegegevens verwachten, die door de deploymentomgeving meegegeven worden. Hoe deze configuratiegegevens gegeven worden (via bestand, of individuele parameters) maakt niet uit. De service en deploymentomgeving moeten wel onderling van elkaar weten hoe de structuur van de configuratiegegevens in elkaar zit. Het grootste nadeel van deze methode is dat een service haast niet meer gewijzigd kan worden na het initialiseren van de service. Een ander nadeel is dat de configuratiegegevens verspreidt over de services liggen.
- **Pull model.** Het pull model heeft bijna enkel voordelen tegenover het push model. De deploymentomgeving geeft bij de creatie van de service enkel de URL mee van een zogenaamde configuratie-server. Deze server bevat alle configuratiegegevens voor elke service. De service

zelf zal dan deze server, met behulp van de URL, aanspreken om de juiste configuratiegegevens op te halen. Dit biedt een aantal voordelen:

- Gecentraliseerde configuratie.
- Een service kan de server pollen om na te gaan of de configuratiegegevens aangepast zijn, en deze dan eventueel op te halen. De service moet hiervoor niet herstart worden.
- Sommige configuratiegegevens zijn gevoelig, zoals databaseinformatie. De server zal deze moeten encrypteren. De service wordt dan wel verwacht de publieke sleutel van de server te hebben zodat hij deze kan decrypteren. Sommige servers decrypteren de configuratiegegevens zelf.

Het grootste nadeel is echter dat de configuratieserver opnieuw een infrastructuur is dat moet opgesteld en onderhouden worden.

Om **monitoring** te implementeren moeten services 'waarneembaar' gemaakt worden. Er moeten hiervoor extra APIs aangemaakt worden, die niet mogen interfereren met de werkelijke functionaliteit van de service. Hiervoor zijn er een aantal hulpmiddelen om een service waarneembaar te maken:

- **Health check API.** Een eenvoudige API dat de status van de service teruggeeft.
- **Log aggregation.** Logbestanden zijn een goede manier om de werking van de service op te volgen. Deze logbestanden worden best geschreven naar een gecentraliseerde logserver, zodat zoeken ondersteund kan worden. Het is ook enkel de verantwoordelijkheid van de logserver om ontwikkelaars te waarschuwen. Traditioneel logt een applicatie naar een welbepaald logbestand op het filesystem. Dit is hier geen goede oplossing, omdat sommige services zelfs geen filesystem zullen hebben. Hierom moet elke service loggen naar stdout. De deploymentomgeving zal dan beslissen wat hij wil doen met deze uitvoer.
- **Distributed tracing.** Het oproepen van een endpoint van de API kan meerdere interne calls maken. Het is vaak moeilijk te achterhalen waarom zo een query traag verloopt. Distributed tracing kent aan elke endpoint een ID toe, en bekijkt de call chain die overlopen wordt. Deze gegevens worden naar een gecentraliseerde server verstuurd waarop analyse kan uitgevoerd worden. Een endpoint wordt gepresenteerd door een trace. Zo een trace bestaat uit geneste spans, die elk een call voorstellen. De endpoint is de top span, en zal elke andere span bevatten.
- **Audit logging.** Het doel van audit logging is om acties van gebruikers te verzamelen. Elke audit log entry heeft een ID dat een gebruiker voorstelt, de actie dat ze uitgevoerd hebben en het domeinobject. Voorbeelden zijn gefaalde loginpoging, toevoegen van items in het winkelmandje, maar uiteindelijk niet betalen. Zulke logs dienen vooral voor customer support en om vreemde activiteiten op te sporen.
- **Application metrics.** Deze tak bestaat uit een metriekservice. Deze metriekservice vraagt gegevens op van de verschillende applicaties. Zulke gegevens zijn onder andere: CPU gebruik, geheugengebruik, schijfgebruik, aantal requests per seconde, request latency en domeinspecifieke gegevens. Een service moet ontworpen zijn zodat al deze gegevens naar de metriekservice kunnen verstuurd worden, en is afhankelijk van het gebruikte framework. De service kan ofwel zelf beslissen om zijn metriecken te versturen naar de metriekservice, of de metriekservice zal elke service pollen om de metriecken op te halen.

Hoofdstuk 9

Containers

Verskillende microservices kunnen onderling elk gebruik maken van verschillende technologieën. Om deze verschillende microservices te deployen zouden al de verschillende dependencies van elke technologie op de server geconfigureerd moeten worden. Dit is natuurlijk niet haalbaar op grote schaal, daarom zou men in eerste instantie virtuele machines kunnen gebruiken waarbij elke verschillende virtuele machine geschikt is voor een specifieke technologiestack. Virtuele machines nemen echter te veel opslag in beslag. Ze nemen zoveel beslag in omdat elke virtuele machine zijn eigen besturingssysteem en kernel bevat. De hypervisor (of virtual machine monitor) geeft elke virtuele machine de illusie dat enkel hun machine toegang heeft tot de resources van het hosttoestel (het toestel waarop de virtuele machines draaien). Er zijn twee types hypervisor:

- **Type 1.** Dit type hypervisor draait rechtstreeks op de hardware van de host en heeft geen behoefte aan een onderliggend besturingssysteem.
- **Type 2.** Dit type hypervisor heeft wel nood aan een besturingssysteem. Dit heeft als voordeel dat er ook applicaties op het hosttoestel kunnen draaien.

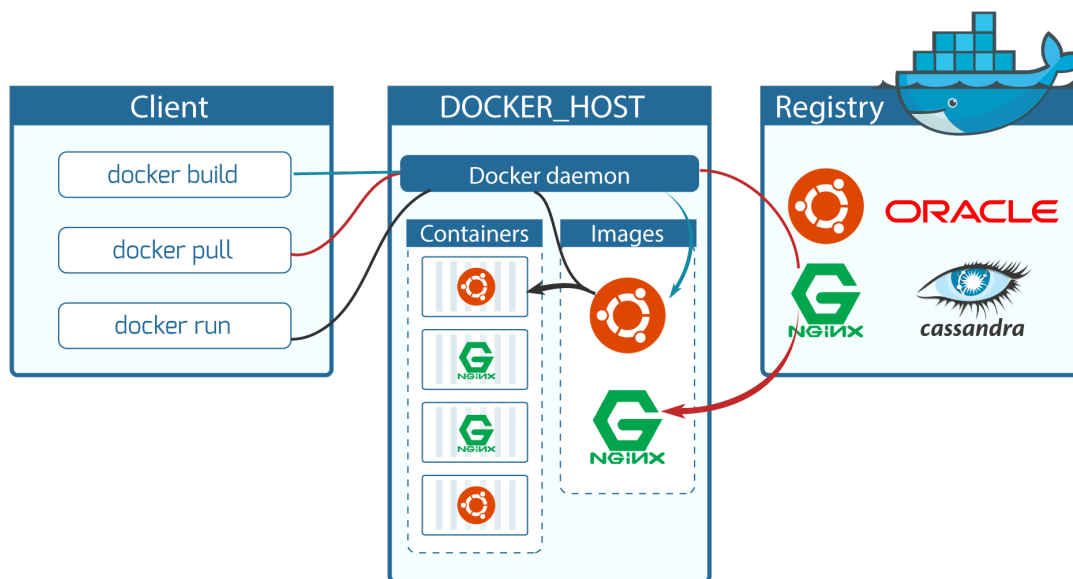
Containers zijn een virtualisatietechniek op besturingssysteemniveau. Een populaire container technologie is Docker, dat gebruik maakt van de linux container functionaliteit.

- **Linux Control Groups (cgroups).** Groeperen van processen, en privileges zetten op deze groepen.
- **Linux namespaces.** Een geïsoleerde weergave van de systeemresources.
- **Changing root (chroot).** Elk process de illusie geven dat ze vanuit de root-directory aangesproken worden.
- **Veilige containers (LSM).** Mogelijkheden per process vastzetten.

Docker:

- Automatisch verpakken en deployen van een applicatie.
- Beschikbaar op Linux, MacOS, Windows.
- Onafhankelijk. Minimale dependencies.
- Grote flexibiliteit in wat er in de container moet.
- Alle containers kunnen gestart en gestopt worden op dezelfde manier.
- Lightweight. Meerdere containers per host mogelijk (nog meer dan virtuele machines).

9.1 Docker Architecture



De **Docker daemon** is verantwoordelijk om containers te starten, stoppen, monitoren, alsook om images op te slaan en te builden. De **Docker client** kan de daemon aanspreken om de operaties van de daemon uit te voeren. De **Registry** bevat images die door de daemon gebruikt kunnen worden.

Een image aanmaken kan als volgt:

```
# Dockerfile to build an Apache2 image
# Base image is Ubuntu
FROM ubuntu:14.04
# Install apache2 package
RUN apt-get update && apt-get install -y apache2 && apt-get clean
```

Syntax van een Dockerfile:

```
1 FROM ubuntu:14.04
2
3 COPY html /var/www/html
4 ADD web-page-config.tar /
5
6 ENV APACHELOG_DIR /var/log/apache
7 USER 73
8
9 EXPOSE 7373/udp 8080
10
11 RUN apt-get update && apt-get install -y \ apache 2 && apt-get clean
12
13 ENTRYPOINT ["echo", "Dockerfile entrypoint Demo"]
```

- **Lijn 1 FROM** De base image van de container. Alle volgende commandos bouwen verder op deze image.

- **Lijn 3 COPY** Bestanden kopiëren van de docker host naar het bestandssysteem van de nieuwe image.
- **Lijn 4 ADD** Gelijkaardig aan COPY, maar kan ook .tar bestanden (die hij zal unzippen) en URLs (die hij zal downloaden) behandelen.
- **Lijn 6 ENV** Een omgevingsvariabele instellen in de nieuwe image.
- **Lijn 7 USER** Een gebruiker toevoegen met een specifiek UID. Deze UID wordt ook gebruikt in volgende RUN, CMD of ENTRYPOINT instructies.
- **Lijn 9 EXPOSE** Deze instructie informeert enkel dat deze poorten zullen gebruikt worden. Docker zal zelf deze poorten niet openzetten.
- **Lijn 11 RUN** Deze instructie bevat commando's die uitgevoerd moeten worden tijdens de buildfase. Het is beter om slechts één RUN instructie te hebben, omdat docker een nieuwe, read-only, laag aanmaakt voor elke instructie.
- **Lijn 13 ENTRYPOINT** Het startpunt van de applicatie. Als deze applicatie stopt, wordt de container ook automatisch gestopt.

Wanneer een container gestart wordt vanuit een image, dan zal Docker een extra, schrijfbare, laag toevoegen. Op deze laag kunnen dan nieuwe bestanden gezet worden. Als de container verwijderd wordt, zullen ook deze bestanden verwijderd worden. Op die manier kunnen dus verschillende containers, die toch dezelfde image hebben, aparte informatie bewaren.

Een container bouwen:

```
docker build -t dockerfile .
```

Hoofdstuk 10

Container orchestration

Drie functies van een orchestration framework:

- **Resource management:** Een groep van machines als één cluster beschouwen, zodat het lijkt alsof deze groep één proces is met zijn eigen CPU-, RAM- en volumegebruik.
- **Scheduling:** Het bepalen welke groep van containers op welke machine moet komen. De default werkwijze is om te kijken naar de systeemresources die een groep nodig heeft, en een daarbijhorende machine te vinden die deze systeemresources kan aanbieden.
- **Service management:** Het blootstelling van de container aan de externe wereld. Ook zal het framework ervoor zorgen dat er genoeg instanties van een bepaalde service zijn. Verder zal het framework load balancing implementeren tussen deze instanties.

10.1 Kubernetes

Kubernetes is een voorbeeld van een orchestration framework.

- Een machine in een cluster kan twee vormen aannemen:
 - **Master:** deze machine beheert de cluster en bevat volgende componenten:
 - Het bevat een API server, die aangesproken kan worden door ontwikkelaars om de nodes aan te spreken.
 - De scheduler bepaalt op welke node een pod (\equiv container, maar specifiek voor kubernetes) moet komen.
 - De controller manager is het proces dat verschillende kubernetes controllers bevat. Voorbeelden van controllers zijn:
 - Replication Controller, die ervoor zorgt dat er een bepaald aantal kopieën van een pod aanwezig zijn in het cluster.
 - Node Controller, die notificaties geeft wanneer een node niet meer bereikbaar is.
 - Endpoints Controller, die pods en services samenvoegt.
 - Tot slot is er nog de etcd storage, die configuratie en de staat van de cluster bewaart. Meestal heeft een cluster maar een klein aantal masters.
 - **Node:** Dit zijn de effectieve machines die de applicatie doen draaien en bevat volgende componenten:

- De kubelet beheert de pods die aanwezig zijn op de node.
- De kube-proxy voorziet een abstracte manier om de node te beheren.
- De cAdvisor is een daemon that metrieke verzamelt.
- De pods zijn de applicatieservices.
- Een pod is een eenheid van deployment in kubernetes, en bestaat uit één of meerdere containers die eenzelfde IP-adres en opslagvolume delen. Kubernetes maakt zelf de pods aan, met behulp van een document dat de gewenste staat beschrijft:

```
apiVersion: apps/v1beta1
kind: Deployment
metadata:
  name: myapp-deployment
spec:
  replicas: 3
  template:
    metadata:
      labels:
        app: MyApp
    spec:
      containers:
      - name: nginx
        image: nginx:1.7.9
        ports:
        - containerPort: 80
```

- Vaak wordt er per pod maar één container geassocieerd, maar het is ook mogelijk om meerdere containers per pod te associëren. Dit is handig als je extra hulpfunctionaliteit wil bieden aan een service zoals:
 - **Sidecar container:** een service die periodiek een git pull doet om de applicatie up te daten. Een andere mogelijkheid is een service die logbestanden verwerkt.
 - **Adapters**
- De service registry is een databank van services, die voor elke service al zijn instanties en hun locaties bijhoudt. Een instantie wordt geregistreerd in de databank bij creatie, en wordt er terug uitgehaald bij destructie. clients moeten enkel nog aan de service registry een query doen, om de instanties op te halen voor een specifieke service.
 - **Client-side discovery:** Een client is gekoppeld aan de service registry en zal zelf load-balancing toepassen. Het nadeel is dat de client nu sterk gekoppeld is aan de service registry en dat er nu discovery logic in elke client aanwezig moet zijn.
 - **Server-side discovery:** De client stuurt nu een request naar een load-balancer service, die op een bekende en vaste locatie ligt. De load-balancer zal nu zelf de service registry aanspreken en load-balancing implementeren. De client moet nu enkel een request sturen naar de load-balancer. Het nadeel is hier nu dat deze load-balancer opnieuw een component is dat moet onderhouden worden. Ook moet het gerepliceerd worden om beschikbaarheid te garanderen.
- Kubernetes maakt gebruik van server-side discovery en vereist het aanmaken van een Kubernetes Service:

```
kind: Service
apiVersion: v1
metadata:
```

```
name: myapp-service
spec:
  selector:
    app: MyApp
  ports:
  - protocol: TCP
    port: 8080
    target-port: 9000
```

Deze service zal clients een juiste pod bezorgen.

- Een load balancer zal voor een bepaalde request bepalen welke instantie teruggeven moet worden. Enerzijds gebeurt dit op basis van de request, zoals bijvoorbeeld de geografische afstand, zodat enkel instanties in de omgeving relevant zijn. Anderzijds moet uit lijst van instanties degene gekozen worden op basis van de huidige capaciteit van een instantie.
- Er zijn drie interessante operaties die uitgevoerd kunnen worden met een load balancer.
 - **Rolling update:** In plaats van elke instantie op hetzelfde moment up te daten, kan er altijd een selectie van instanties offline gehaald worden. De load-balancer stuurt dan de requests door naar de overige instanties.
 - **Canary release:** Een kleine selectie van requests (bv 5%) worden naar een instantie gestuurd die een nieuwe software update bevat. Op die manier worden weinig mensen getroffen door bugs, indien deze aanwezig zouden zijn.
 - **A/B testing:** Dit dient eerder voor marketingdoeleinden. De helft van de gebruikers krijgen versie A, en de andere helft krijgen versie B van een applicatie.

10.2 Dimensies van cloud computing

Drie dimensies in cloud computing

- Essentiële eigenschappen.
- Cloud service models.
- Cloud deployment models.

10.2.1 Essentiële eigenschappen

vijf eigenschappen

- **On-demand:** een resource moet op elk moment beschikbaar zijn.
- **Elasticiteit:** het aantal beschikbare resources moet instelbaar zijn, afhankelijk van de huidige nood.
- **Resource pooling:** De resources van de cloud provider worden gebruikt door meerder gebruikers. Een individuele gebruiker kan slechts op abstract niveau resources specificeren zoals het aanvragen van 6GB ram.
- **Metered:** Het gebruik van resources wordt in het oog gehouden. Meestal moet enkel voor de effectief gebruikte resources betaald worden.
- **Network access:** Een API is beschikbaar om de resources aan te spreken.

10.2.2 Cloud service models

eerst stakeholders beschrijven:

- **Cloud provider:** De provider beheert de hardware en software en stelt deze ter beschikking voor cloud users. De cloud provider is verantwoordelijk om de afgesproken requirements met de verschillende cloud users na te leven, meestal in de vorm van minimale garanties die de cloud provider moet leveren. Voorbeelden van cloud providers zijn: Amazon, Google en Microsoft.
- **Cloud users:** De cloud users gebruiken de resources van de cloud provider om applicaties te hosten, die dan gebruikt kunnen worden door end users. De cloud user heeft geen zicht op de interne structuur van de cloud provider, en kan enkel resources aanvragen. Er is geen formeel contract tussen cloud users en end users. Een voorbeeld van een cloud user is Netflix.
- **End users:** De end users maken gebruik van de cloud applicaties van de cloud users. Meestal is hier een bepaalde kost aan verbonden (jaarlijkse subscriptie).

vijf service models

- **Metal as a Service:** Huren van fysieke servers, kabels en electriciteit. De provider helpt met het installeren van onder andere een besturingssysteem, configuratie van VLANs en andere toestellen op het netwerk ontdekken.
- **Infrastructure as a Service:** Huren van virtuele machines, opslag en netwerkinfrastructuur.
- **Container as a Service:** Huren van pregeconfigureerde orchestratieplatformen zoals Kubernetes.
- **Platform as a Service:** Huren van middleware producten zoals database management systemen, applicatieservers, message brokers, enz.
- **Software as a Service:** Huren van software.

10.2.3 Cloud deployment models

drie deployment models

- **Public cloud:** Iedereen kan de systeemresources huren en gebruiken.
- **Private cloud:**
- **Hybrid cloud:**

10.3 Elastische schaling

twee vormen van schaling

- **Statische schaling:** De systeembeheerder voert zelf een commando in om meer of minder resources te voorzien, meestal als het te laat is.
- **Elastische schaling:** Het systeem voorziet zelf schaling, in kleine intervallen, op basis van de huidige workload.

drie typen workloads

- **Statische workload:** In dit geval is de workload nagenoeg altijd dezelfde, zodat elastische schaling niet zo nuttig lijkt. Toch is het handig om, indien een machine faalt, snel een nieuwe machine werkend te hebben. Elastische schaling vergemakkelijkt dit proces.
- **Periodieke workload:** Bij voorgedefinieerde pieken, zoals applicaties die enkel beschikbaar moeten zijn per dag, is het wel handig om elastische schaling te hebben. Bij statische schaling kan je vooraf genoeg resources voorzien, maar op normale momenten zijn er dan teveel resources beschikbaar, zodat er meer moet betaald worden.
- **Dynamische niet-periodieke workload:** Deze niet-periodieke workloads kunnen vooraf geweten zijn (ticketverkoop) of niet (opeens meer interesse in bepaalde website).

Om elastische schaling toe te passen kan men steunen op twee types:

- ! **Verticale schaling:** De bestaande infrastructuur uitbreiden (meer geheugen, CPU, harde schijven in nodes steken). Dit is geen goede techniek, omdat het neerschalen niet eenvoudig toelaat. Alle nieuwe hardware zou er dan uit moeten gehaald worden.
- ✓ **Horizontale schaling:** Nieuwe nodes voorzien die dezelfde infrastructuur hebben. Op deze manier kan zelfs de capaciteit van de grootste node overschreden worden.

Deel III

Distributed Data Storage & Processing

Hoofdstuk 11

De uitdagingen van moderne data

Data-intensieve applicaties moeten rekening houden met volgende vier categorieën:

- **Volume.** De hoeveelheid opslag die over verschillende plaatsen moeten opgeslagen worden.
- **Velocity.** De snelheid waarop nieuwe informatie actueel wordt.
- **Variety.** De verschillende soorten types van data die bestaan.
- **Veracity.** De betrouwbaarheid van de data.

Hoofdstuk 12

Datamodellen

12.1 Het relationeel model

zie cursus relationele gegevensbanken, belangrijk is om gewoon de nadelen te kennen zoals:

- ! Er zou een brede tabel nodig zijn met honderden kolommen (waarvan de meeste dan NULL zijn) om bijvoorbeeld de producten van een winkel op te slaan. Elk product heeft diverse kenmerken die eigen zijn aan een bepaalde productcategorie.
- ! Men zou dit kunnen oplossen door een nieuwe tabel te maken per productcategorie, maar dit introduceert veel tabellen en relaties (te vergelijken met het verhogen van de normaalvorm).

12.2 Het document model

Informatie in een document model wordt in een boomstructuur met one-to-many relaties opgeslagen, en is daarom dus perfect voor one-to-many relaties. Een document wordt opgeslagen als één string, meestal in JSON of XML formaat, op deze manier volstaat één enkele query om een hele object, en zijn relaties op te vragen.

Een extreem voordeel van het document model is dat het geen restricties oplegt aan de data. Er kunnen twee producten zijn die in het systeem herkend worden als "Product" maar een andere interne structuur hebben. Het document model wordt dus best gekenmerkt door:

- Flexibiliteit in het schemamodel. Dit wordt ook wel "schema-on-read" genoemd aangezien de client niet op voorhand kan weten welke structuur het document zal hebben.
- Data lokaliteit. Hiermee wordt bedoeld dat een document als één enkelvoudige string wordt opgeslagen, en alle informatie zit dan ook in die string. Er is geen nood aan het join-of-indexeringmechanisme. Een document wordt altijd in zijn geheel ingelezen, dit kan een nadeel zijn indien slechts een beperkt aantal informatie van dat document nodig is.

12.3 Het graaf model

Het document model volstaat voor one-to-many relaties, maar is niet perfect voor many-to-many of many-to-one relaties want dan moeten er toch "joins" gedaan worden, maar dan op documenten. Het graaf model kent twee soorten:

1. Een normale graaf met knopen en verbindingen, die beiden attributen kunnen hebben.
2. Een drievoudig model waarbij alle informatie opgeslagen wordt als: $\text{SUBJECT} \rightarrow \text{PREDICATE} \rightarrow \text{OBJECT}$

Gekende graafalgoritmen kunnen toegepast worden op dit model. Het graaf model heeft een aantal use cases:

- **Transportnetwerk.** Een graaf is de geschikte manier om een wegennet voor te stellen.
- **Linkanalyse.** Het zoeken van objecten die gerelateerd zijn aan een ander object (bv vrienden van vrienden zoeken).

12.4 Het kolomfamilie model

Informatie wordt opgeslagen in tabellen die rijen en kolommen bevatten. Een tabel bevat één of meerdere kolomfamilies, die gedefinieerd worden bij de tabel zelf. Elke kolomfamilie is een verzameling van rijen, geïndexeerd door een rij sleutel. Een rij sleutel moet uniek zijn binnen een kolomfamilie. Elke rij kan een andere verzameling van kolommen hebben. Het kan beter gezien worden als een soort van map met als sleutel de kolomfamilie en als waarde een andere map met als sleutel de rij sleutel.

Hoofdstuk 13

Opslaan en ophalen van informatie

Er zijn twee soorten opslagmethoden waaruit gekozen moet worden:

- **OLTP (Online Transaction Processing):** De databank zal gebruikt worden om vaak queries op uit te voeren. Deze queries zullen slechts een beperkt aantal resultaten teruggeven. De grootste bottleneck is het zoeken naar de juiste records.
- **OLAP (Online Analytic Processing):** (\equiv datawarehouse) De databank zal gebruikt worden om slechts een beperkt aantal queries op uit te voeren, maar deze queries zal veel gegevens moeten scannen.

De voornaamste verschillen tussen beiden zijn:

Eigenschap	OLTP	OLAP
Leespatroon	Klein aantal records per query	Aggregeren over groot aantal records
Schrijfpatroon	Random-access, low latency	Bulk import
Gebruikers	Meestal via een bepaalde applicatie	Een interne analyst
Wat voor data?	Meest recente informatie	Historische informatie
Grootte dataset	Gigabytes-terabytes	terabytes-petabytes

Drie manieren om informatie naar de schijf weg te schrijven, en maken elk gebruik van indexen om de informatie snel terug te vinden. Page- en log-based worden vaak gebruikt bij OLTP systemen terwijl column-based gebruikt wordt bij OLAP systemen.

- **Page-based:** Deze methode maakt gebruik van de B-tree. In deze context wordt een knoop van een B-tree een "pagina" genoemd. Elke pagina van de B-tree moet in zijn geheel ingeladen worden, met alle bijhorende informatie. Elke pagina bevat ook verwijzingen naar andere pagina's, die op de schijf staan. Informatie updaten komt erop neer de juiste pagina te zoeken (meestal een blad, zie algoritmen II), en daarin de waarde aan te passen, gevolgd door de pagina terug naar de schijf te schrijven. Een B-tree heeft maar een beperkte hoogte, maar is eerder breed. Het opzoeken van willekeurige informatie kan hierdoor snel gaan, maar is niet geschikt voor veel schrijfoperaties.
- **Log-based:** Informatie wordt gesorteerd bewaard in een lijst van bestanden, Sorted String Tables genoemd. Om de juiste waarde te vinden, wordt er in het geheugen een lijst van indexen bijgehouden, samen met hun byte offset in het bestand, die kunnen gebruikt worden tijdens een opzoeking. Bij deze methode wordt er gebruik gemaakt van een zogenaamde **Log-Structured Merge Tree (LSM Tree)**, om ervoor te zorgen dat de informatie werkelijk gesorteerd blijft. Het principe werkt als volgt:

- Er wordt in het geheugen een zelf-balancerende boom bijgehouden (rood-zwarte boom, splayboom, ..., zie algoritmen II), waaraan toegevoegd kan worden.
- Eens een bepaalde threshold overschreden wordt, zal de boom geflushd worden naar de schijf. Dit komt neer op de boom in order overlopen en de elementen te schrijven naar de schijf.
- Een query zal nu eerst in de geheugenboom kijken, dan in de meest recente SStable, enz.

Een bloom filter optimaliseert de toegang tot de SStables op volgende manier:

- Er worden meerdere hashfuncties op elke sleutel losgelaten.
- De output van deze hashfuncties dienen om bepaalde bits van de bloom filter aan te zetten.
- Bij het zoeken naar een sleutel, worden diezelfde hashfuncties losgelaten op de zoeksleutel. Er is 100% zekerheid dat de sleutel niet in de SStable zit als alle bits voor de outputs niet aanstaan.

Bij een te groot aantal SStables worden deze tabellen samengevoegd in één bestand. Verschillende bestanden kunnen dezelfde sleutels bevatten, daarom wordt enkel de meest recente sleutel bijgehouden.

De voornaamste verschillen tussen een B-tree en een LSM Tree zijn: Het samenvoegproces van

Eigenschap	B-tree	LSM Tree
Extra schrijfoverhead	Eerst naar logbestand schrijven, dan naar pagina.	Samenvoegen van SStables.
Schijffragmentatie	Ruimte van een pagina wordt niet altijd helemaal gebruikt	Sequentieel schrijven van gecomprimeerde SStables.

een LSM Tree kan de normale schrijfoperaties beïnvloeden, en zou zelfs te traag zijn bij een groot aantal inkomende schrijfoperaties, zodat het aantal niet-samengevoegde delen stijgt.

Een B-tree voldoet beter aan het transactioneel model: elke sleutel komt maar op één plaats voor en er kunnen locks geplaatst worden op de B-tree.

- **Column-based:** Het uitvoeren van analytische queries, zoals bijvoorbeeld op het sterschema, wordt gerealiseerd met een kolomgeëïntende methode. In plaats van de waarden van alle attributen van een rij op te halen zoals bij een normale SQL databank, wordt er gekozen om de waarden van één enkele kolom op een apart bestand te zetten. Elke kolom krijgt dan een ander bestand, zodat er efficiënt een beperkt aantal kolommen kan ingelezen worden. Deze manier laat compressie toe aangezien veel waarden in een kolom dezelfde kunnen zijn.

Hoofdstuk 14

Gedistribueerde informatie

Waarom is het belangrijk dat informatie op verschillende nodes beschikbaar is?

- **Schaalbaarheid:** Een toestel heeft maar een maximum aantal geheugen, opslagplaats en schijfoperaties per seconde. Meerdere nodes betekent dat de belasting kan verdeeld worden tussen de nodes.
- **Fouttolerantie:** Een backup voorzien voor in het geval dat een andere node uitvalt.
- **Latency:** Nodes geografisch verspreiden zodat connecties vanuit andere continenten niet traag zijn.

Er wordt best gebruik gemaakt van het horizontaal schaalschema. Dit heeft als voordeel dat er geen speciale hardware vereist is, en er gewoon machines kunnen bijgekocht worden indien dit nodig zou zijn.

Er zijn twee belangrijke patronen om data te distribueren:

- **Replicatie:** Dit is eenvoudig alle data dupliceren op elke verschillende node, zodat ze allemaal dezelfde data bevatten. De voordelen zijn: hoge databeschikbaarheid en fouttolerantie tegen het uitvallen van een node door de redundantie van de informatie. Het nadeel is: hoe moeten we ervoor zorgen dat alle nodes over dezelfde data beschikken (zie sectie 14.1)?
- **Partitionering (sharding):** De grote hoeveelheid data kan ook gepartitioneerd worden, zodat elke node zijn unieke verzameling van gegevens bevat. Partitionering heeft een aantal voordelen: Elke partitie moet slechts zijn beperkte data behandelen. Hoe groter de dataset wordt, hoe minder operaties een bepaalde partitie zal moeten uitvoeren, aangezien er meer partities zullen ingevoerd worden zodat de data meer verspreidt ligt over alle partities. Het nadeel is: hoe kunnen we bepalen op welke node een bepaald stukje informatie moet komen. Idealiter heeft elke node dezelfde workload.

In praktijk worden replicatie en partitionering gecombineerd. Eerst wordt partitionering toegepast, waarna deze partities ook nog gerepliceerd worden.

14.1 Replicatie

Er zijn twee modellen om aan replicatie te doen: het leader-follow model en het leaderless model. Een node die gerepliceerd wordt een replica genoemd.

14.1.1 Leader-Follower model

Dit model verloopt in drie stappen:

1. Een replica wordt tot leader gemaakt. Enkel op deze replica mogen er writeoperaties plaatsvinden.
2. Elke andere replica is een follower. Elke keer dat de leader naar zijn schijf schrijft, zal de leader ook de gewijzigde data doorsturen, in de vorm van een replication log, naar alle followers. Deze replication log bevat instructies dat elke follower moet ondernemen zodat ze de update juist kunnen uitvoeren.
3. Een client kan een readoperatie zowel aan de leader als aan een follower aanvragen.

Deze manier garandeert dat de followers ooit zullen convergeren naar de juiste toestand.

Met dit model moeten er zowel read-after-write consistency en monotonic reads gegarandeerd zijn:

- **Read-after-write consistency:** Garanderen dat wat er geschreven is naar de databank, direct kan gelezen worden. Dit wordt gerealiseerd door degene die de wijziging heeft gedaan op een item, enkel een query kan sturen naar de leader. Een andere manier is om een timestamp client-side van de laatste schrijfoperatie bij te houden, zodat de replica kan controleren of zijn databank al up to date is.
- **Monotonic reads:** Er moet garantie zijn dat, indien meerdere reads op hetzelfde item worden uitgevoerd, dat de data consistent in de tijd is. Dit wil zeggen dat als een gebruiker een stukje informatie ophaalt, dat het bij de volgende query geen vroegere informatie van die item zal ophalen. Dit kan opgelost worden door dezelfde reads enkel aan dezelfde replica te vragen.

14.1.2 Leaderless model

In dit model kan er naar elke replica geschreven worden, meestal met behulp van een coördinator, zodat de client zelf niet de locaties van de replicas moet kennen. De coördinator legt niet de volgorde van de schrijfoperaties vast, het stuurt enkel maar de query naar elke replica. Een update wordt naar elke replica gestuurd en elke replica zal dit aanpassen in zijn databank. Het kan zijn dat een replica op dat moment offline is, zodat hij deze schrijfoperatie niet krijgt. Om te voorkomen dat een query naar een replica gestuurd wordt die geen aangepaste database heeft, wordt een query naar meerdere replicas verstuurd. Een leesoperatie zorgt er ook voor dat elke replica terug een juiste staat heeft, zogenaamd read repair:

1. De client vraagt informatie op aan de coördinator.
2. De coördinator verstuurt de query naar een willekeurige replica.
3. De coördinator vraagt nu aan alle andere replicas dezelfde query.
4. De waarde die het meest voorkomt wordt gekozen als antwoord op de query en wordt verstuurd naar de client.
5. Elke replica die niet de geaccepteerde waarde heeft, wordt geupdate met deze nieuwe waarde.

! Het nadeel aan dit mechanisme is dat, indien een waarde niet gelezen wordt, deze ook niet aangepast zal worden. Daarom wordt er nog een anti-entropy process ingevoerd. Dit is een achtergrondproces dat zelfstandig naar verschillen zoekt in de replicas.

Hoeveel gefaalde replicas mogen we tolereren? Dit wordt besproken met behulp van drie notaties:

- **N**: het aantal replicas dat het systeem wenst te hebben.
- **W**: het aantal replicas dat een bepaalde schrijfoperatie moet goedkeuren (effectief schrijven naar de databank).
- **R**: het aantal replicas waarnaar een leesoperatie gestuurd wordt.

Vaak wordt als quorum $W + R > N$ genomen, zodat er zeker een overlap is tussen schrijfbaar en leesbare replicas (minstens één replica waarnaar geschreven als van gelezen kan worden). Bijhorende restricties zijn:

- $W < N$, zodat er schrijfoperaties mogelijk zijn ook al is er een replica offline.
- $R < N$, zodat er leesoperaties mogelijk zijn ook al is er een replica offline.

Op deze manier mogen er $W + R - N$ replicas offline zijn, om toch nog aan het quorum te voldoen.

Er kan gekozen worden voor $W + R \leq N$ voor snellere communicatie, maar dan bestaat er een hogere kans voor foute waarden te lezen.

Wat doen als er toch meer dan $W + R - N$ nodes offline zijn? Men zou kunnen kiezen om de schrijfoperatie toch te accepteren, en te schrijven naar replicas die normaal geen informatie bij voor die sleutel bijhouden. Dit heet een sloppy quorum.

Hoofdstuk 15

Partitionering

Vorig hoofdstuk ging over de replicatie van nodes, nu gaat het over de partitionering. Hier wordt bepaald hoe de informatie over de verschillende partities moet verspreid worden. Er zijn twee uitdagingen:

- De informatie moet uniform verdeeld worden over elke node.
- Het aantal nodes minimaliseren vanwaar gelezen moet worden tijdens een query.

Methoden om dit te implementeren:

- **Partitioneren op sleutelintervallen.** Bij deze methode heeft elke partitie een bepaald sleutelbereik. In het geval van voornamen kan dit bijvoorbeeld $[A - E]$ zijn. Dit heeft als gevolg dat in elke partitie de sleutel gesorteerd bijgehouden kan worden. Het nadeel is direct dat bepaalde sleutels meer voorkomen dan andere. Er zijn meer namen die met een B beginnen dan met een X. Dit heet data skew en resulteert in hotspots: bepaalde nodes zullen meer werk moeten verrichten dan andere nodes.
- **Partitioneren op de hash van de sleutel.** Dit tracht willekeurige data uniform te verdelen. De nodes zullen dan in plaats van een sleutelinterval, een hashinterval hebben. De informatie is nu wel niet meer gesorteerd.

15.1 Herbalancering

Soms moeten partities hergebalanceerd worden. Gebruik hierbij NIET $H(m) = m \bmod N$. Als het aantal nodes N wijzigt, moet elke hash opnieuw berekend worden. Creëer meer partities dan nodes, en ken aan elke node een aantal partities toe. Bij het opschalen kan de nieuwe node een aantal partities van de andere nodes nemen. In de praktijk wordt dynamische partitionering gebruikt: wanneer een bepaalde partitie een aantal bytes overschrijdt, dan wordt de partitie opgesplitst en naar een andere node verzonden.

15.2 Request Routing

Tot slot moet bij een query nog de juiste partitie aangesproken worden. Request routing lost dit probleem op, en is eigenlijk gewoon het service discovery probleem.

- De client zou zelf kunnen beslissen naar welke node hij de request stuurt. Als de node de partitie niet bevat, dan moet de node het request doorsturen naar de juiste node. Een ander geval is dat de client wel weet waar de partitie zich bevindt, en gewoon die node aanspreekt.
- Een beter manier, is om een routing tier in te voegen, die de client kan aanspreken. De routing tier implementeert de logica bevat om de juiste node te selecteren. Elke node moet zichzelf registreren aan de routing tier.

Hoofdstuk 16

Consistentie en Consensus

Hoe krijgen we de databank in een consistente staat?

- **Linearizability:** Deze methode geeft de illusie dat er slechts een enkele kopie is van de informatie. Tijdens een schrijfoperatie kan de waarde van een attribuut veranderen, maar het is niet geweten wanneer exact. Als iemand een query doet die deze waarde opvraagt, kan het ofwel de oude of de nieuwe waarde zijn. Vanaf dat een client de nieuwe waarde heeft ontvangen, moet elke andere client ook deze nieuwe waarde ontvangen bij het uitvoeren van dezelfde query. *ToDo: wtf is dit zelf* Deze kent een aantal voordelen:

- ✓ Voorkomen dat twee items dezelfde unieke identifier hebben op hetzelfde moment. Slechts één item zal goedgekeurd worden.

✓

De nadelen zijn:

- ! De eenvoudigste implementatie is werkelijk maar één kopie bijhouden. Als de node uitvalt die deze kopie bijhoudt, vooraleer er naar de databank is geschreven, is de informatie wel verloren.
- ! Bij gepartitioneerde nodes moet elke andere node stoppen met requests te verwerken tot dat